



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS DE QUIXADÁ
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

FRANCISCO EDINALDO DOS SANTOS SILVA

**EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA MRAG DE
GRANULARIDADE FINA VOLTADA PARA DOCUMENTOS DIDÁTICOS EM PDF**

QUIXADÁ

2026

FRANCISCO EDINALDO DOS SANTOS SILVA

EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA MRAG DE
GRANULARIDADE FINA VOLTADA PARA DOCUMENTOS DIDÁTICOS EM PDF

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Campus de Quixadá da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Ciência da Computação.

Orientador: Prof. Dr. Cristiano Bacelar
de Oliveira

QUIXADÁ

2026

FRANCISCO EDINALDO DOS SANTOS SILVA

EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA MRAG DE
GRANULARIDADE FINA VOLTADA PARA DOCUMENTOS DIDÁTICOS EM PDF

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Campus de Quixadá da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Ciência da Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Cristiano Bacelar de Oliveira (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXXX XXXXXX XXXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXXX XXXXXX XXXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXXX XXXXXX XXXXXXXX
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, pelo apoio incondicional e motivo de orgulho, e aos meus amigos, que dividiram e facilitaram essa longa trajetória.

RESUMO

Este trabalho apresenta o desenvolvimento de uma arquitetura denominada EDGAR, que integra um motor de Geração Aumentada por Recuperação Multimodal (MRAG) voltado à otimização da compreensão de documentos didáticos em PDF. O sistema estrutura-se em um *pipeline* de engenharia de dados dividido em fluxos operacionais assíncrono (*offline*) e síncrono (*online*), utilizando modelos de análise de layout de documentos (DLA) e algoritmos de OCR localizado para viabilizar buscas em granularidade fina. Essa abordagem permite isolar componentes textuais e visuais relevantes antes da formulação das respostas, contribuindo para a mitigação de alucinações causadas por ruídos contextuais inerentes à complexidade estrutural de materiais didáticos. As informações organizadas por meio de uma indexação híbrida, visual e vetorial, são utilizadas pela aplicação cliente Luminia Reader, que atua como interface de leitura web para o estudante. A avaliação experimental busca validar a viabilidade técnica e a precisão da arquitetura ao operar com modelos de linguagem de código aberto (*open-source*). Como contribuição, o EDGAR propõe uma infraestrutura eficiente, sem necessidade de treinamento adicional (*training-free*), para apoiar interações responsivas e de baixa latência entre o aluno e o material didático.

Palavras-chave: Geração Aumentada por Recuperação; Visão computacional; Materiais didáticos; Granularidade fina.

LISTA DE FIGURAS

Figura 1 – Fluxograma detalhado do pipeline de dados da arquitetura EDGAR.	24
Figura 2 – Diagrama de sequência da interação cliente-servidor no fluxo online.	28

LISTA DE TABELAS

Tabela 1 – Análise comparativa dos trabalhos relacionados e o presente trabalho.	20
Tabela 2 – Matriz de configuração da infraestrutura, modelos e métricas experimentais.	30
Tabela 3 – Cronograma.	31

SUMÁRIO

1	INTRODUÇÃO	9
1.1	Objetivos	12
<i>1.1.1</i>	<i>Objetivo Geral</i>	<i>12</i>
<i>1.1.2</i>	<i>Objetivos Específicos</i>	<i>12</i>
2	FUNDAMENTAÇÃO TEÓRICA	13
2.1	Grandes modelos de linguagem e alucinações no ensino	13
2.2	Geração aumentada por recuperação tradicional e suas limitações . . .	14
2.3	Geração aumentada por recuperação multimodal e modelos de visão . .	15
2.4	Segmentação de layout e processamento de documentos	16
3	TRABALHOS RELACIONADOS	18
3.1	ColPali: Efficient Document Retrieval with Vision Language Models . .	18
3.2	LILaC: Late Interacting in Layered Component Graph for Open-domain Multimodal Multihop Retrieval	18
3.3	SLEUTH: Resolving Evidence Sparsity via Agentic Context Engineering for Long-Document Understanding	19
3.4	Análise Comparativa	20
4	METODOLOGIA	22
4.1	Visão geral e premissas arquiteturais do sistema	22
4.2	O pipeline de ingestão e indexação (fluxo offline)	24
<i>4.2.1</i>	<i>Fase 1: Unificação visual e normalização de entrada</i>	<i>24</i>
<i>4.2.2</i>	<i>Fase 2: Análise de layout de documentos (DLA)</i>	<i>25</i>
<i>4.2.3</i>	<i>Fase 3: Isolamento geométrico de componentes (cropping)</i>	<i>25</i>
<i>4.2.4</i>	<i>Fase 4: Extração localizada de texto (OCR seletivo)</i>	<i>26</i>
<i>4.2.5</i>	<i>Fase 5: Vetorização e indexação multimodal híbrida</i>	<i>26</i>
4.3	O pipeline de recuperação e geração (fluxo online)	26
<i>4.3.1</i>	<i>Fase 6: Recuperação multimodal híbrida e casamento de coordenadas . .</i>	<i>27</i>
<i>4.3.2</i>	<i>Fase 7: Engenharia de contexto purificado e inferência</i>	<i>27</i>
<i>4.3.3</i>	<i>Interação cliente-servidor e renderização de evidências</i>	<i>28</i>
4.4	Validação	28
<i>4.4.1</i>	<i>Ambiente de Execução e Infraestrutura Computacional</i>	<i>29</i>

4.4.2	<i>Corpus de Avaliação (Dataset Didático)</i>	29
4.4.3	<i>Métricas e Protocolo de Avaliação</i>	29
4.4.4	<i>Cronograma</i>	30
5	RESULTADOS PRELIMINARES	32
5.1	Resultados do Motor de Dados (EDGAR)	32
5.2	Protótipo da Interface Cliente (Luminia Reader)	32
6	CONCLUSÕES E TRABALHOS FUTUROS	33
	REFERÊNCIAS	34

1 INTRODUÇÃO

O avanço acelerado da Inteligência Artificial (IA) generativa tem impulsionado transformações profundas no cenário educacional, com os grandes modelos de linguagem (LLMs) emergindo como ferramentas promissoras para mediar a relação entre o estudante e o conhecimento (Kasneci *et al.*, 2023). Aplicações baseadas nesses modelos passaram a ser exploradas em tarefas como tutoria automatizada, sumarização de materiais didáticos e resposta a perguntas sobre conteúdos acadêmicos, abrindo novas possibilidades para o aprendizado assistido por IA. Contudo, apesar da alta capacidade de articulação textual, esses modelos apresentam uma limitação estrutural crítica para o ambiente educacional: a alucinação semântica. Esse fenômeno é caracterizado pela geração de respostas que, embora gramaticalmente fluidas, são factualmente incorretas ou completamente desconectadas das fontes de dados consultadas, o que compromete diretamente a confiabilidade da informação entregue ao estudante (Raschka, 2024).

Para mitigar essa vulnerabilidade e ancorar as respostas em fontes de dados verificáveis, Lewis *et al.* (2020) introduziram a arquitetura de *Retrieval-Augmented Generation* (RAG), uma abordagem que atua como um intermediário que extrai blocos de informação de uma base de conhecimento externa e os injeta no contexto do modelo antes da geração da resposta, garantindo a proveniência dos dados e reduzindo a ocorrência de alucinações. No contexto educacional, essa arquitetura representa um avanço relevante, pois possibilita que sistemas de IA respondam com base no conteúdo real dos materiais didáticos fornecidos pelo próprio estudante ou pela instituição.

Entretanto, o RAG tradicional foi concebido para operar sobre repositórios textuais lineares, o que representa uma limitação significativa diante da natureza dos documentos acadêmicos reais. Conforme apontado por Gao *et al.* (2023), o processamento textual padrão frequentemente fragmenta e corrompe dados semiestruturados presentes em PDFs. Além disso, mecanismos de recuperação baseados puramente em texto mostram-se insuficientes para lidar com documentos cuja transmissão de conhecimento depende de layouts complexos, tabelas, infográficos e diagramas visuais, elementos amplamente presentes em livros didáticos e artigos científicos (Faysse *et al.*, 2025; Yun *et al.*, 2025). Nesse contexto, a evolução para arquiteturas de *Multimodal Retrieval-Augmented Generation* (MRAG) impõe-se como caminho natural, uma vez que a compreensão integral de um documento educacional exige que o motor de busca seja capaz de interpretar simultaneamente as dimensões textuais e visuais que estruturam a informação.

No entanto, apesar dos avanços que a transição para MRAG representa, as soluções

presentes na literatura ainda divergem entre eficiência computacional e precisão granular, não atendendo plenamente às exigências do domínio educacional. Abordagens baseadas puramente em Visão Computacional, como a arquitetura ColPali, proposta por Faysse *et al.* (2025), introduziram a recuperação direta de imagens de páginas inteiras utilizando mecanismos de “*interação tardia*”. Apesar de serem mais rápidas por eliminarem processos custosos de reconhecimento óptico de caracteres (*Optical Character Recognition – OCR*), essas arquiteturas operam em uma granularidade fixa de página, o que frequentemente insere ruído visual irrelevante no contexto do modelo e dilui a precisão em consultas específicas (Yun *et al.*, 2025).

Para contornar esse excesso de ruído e mitigar alucinações, frameworks recentes como o SLEUTH (Liu *et al.*, 2025), empregam múltiplos agentes de IA colaborativos para refinar a busca em documentos longos. Paralelamente, sistemas como o LILaC (Yun *et al.*, 2025) fragmentam o documento em grafos de componentes em camadas para interligar explicitamente parágrafos, tabelas e imagens, alcançando alta precisão em raciocínios que exigem cruzar informações de múltiplas páginas. Contudo, tanto a orquestração de múltiplos agentes quanto a construção de grafos complexos combinada com a decomposição de consultas via LLMs impõem uma elevada carga computacional e aumentam a latência do sistema (Liu *et al.*, 2025; Yun *et al.*, 2025).

Além disso, o foco primário dessas tecnologias tem sido o domínio aberto, científico ou administrativo (Liu *et al.*, 2025; Yun *et al.*, 2025), negligenciando a estrutura pedagógica única, expressa na relação direta entre teoria, exercícios e diagramas explicativos, intrínseca aos materiais didáticos.

O presente trabalho, intitulado EDGAR, propõe o desenvolvimento de uma arquitetura de Geração Aumentada por Recuperação Multimodal (MRAG), concebida para o contexto educacional. O sistema tem como objetivo indexar e recuperar, com alta precisão e baixo custo computacional, tanto o conteúdo textual quanto a estrutura visual de documentos didáticos complexos, incluindo tabelas, gráficos e diagramas. Em vez de depender de uma estrutura custosa baseada em múltiplos agentes ou da modelagem de grafos genéricos de domínio aberto, a solução introduz um método de indexação voltado à compreensão da hierarquia semântica do material de estudo. Ao isolar e recuperar o recorte visual exato associado ao seu respectivo contexto textual, a arquitetura busca fornecer ao modelo gerador um bloco de informação mais consistente, contextualizado e com menor presença de ruídos.

Dessa maneira, este projeto apresenta contribuições relevantes para a segurança,

veracidade e confiabilidade da informação no processo de ensino-aprendizagem mediado por IA, uma vez que a ocorrência de alucinações compromete diretamente o propósito educacional da tecnologia. Nesse sentido, a relevância do trabalho está relacionada à preservação do elo pedagógico entre elementos textuais e visuais, mantendo-os alinhados à estrutura original do conteúdo. Para implementar, testar e validar o ecossistema proposto, este trabalho prevê o desenvolvimento do Luminia Reader, um protótipo de leitor de documentos baseado na web, concebido como a camada de aplicação cliente do EDGAR. Essa integração possibilita a execução responsiva e fluida de consultas em tempo real, mesmo em cenários com restrições de infraestrutura computacional no servidor. Como resultado, a abordagem busca mitigar falhas de forma proativa por meio da curadoria estrutural do contexto, reduzindo ruídos visuais e textuais antes da etapa de geração da resposta pelo modelo de linguagem.

Para alcançar os objetivos propostos, o desenvolvimento do ecossistema EDGAR seguirá um percurso metodológico organizado em etapas de especificação dos requisitos arquiteturais, modelagem dos pipelines de dados e desenvolvimento do protótipo da interface web. Os recursos tecnológicos previstos baseiam-se no uso de ferramentas e modelos de código aberto (*open-source*), incluindo redes neurais pré-treinadas para análise de layout, motores de reconhecimento óptico de caracteres e bancos de dados vetoriais voltados à indexação e recuperação semântica. Essa escolha busca garantir a reprodutibilidade da pesquisa e a viabilidade econômica de sua implementação prática em servidores de hospedagem de médio porte.

A avaliação da arquitetura proposta será conduzida por meio de um plano experimental destinado a medir tanto a latência das consultas no fluxo síncrono quanto a fidelidade semântica das respostas geradas pelo modelo de linguagem com 8 bilhões de parâmetros (8B). Como limitação deste estágio da pesquisa, o escopo restringe-se à validação estrutural do pipeline EDGAR em documentos de domínio educacional normalizados no formato PDF. Embora o ecossistema do Luminia Reader seja projetado para receber slides de apresentação e outros arquivos textuais conversíveis na camada inicial de ingestão, o núcleo de processamento limita-se, nesta fase, ao fluxo estruturado em páginas. Portanto, não são contemplados, neste momento, formatos de texto fluido sem paginação nativa, como arquivos EPUB brutos, nem documentos baseados em hipertextos interativos externos.

1.1 Objetivos

1.1.1 *Objetivo Geral*

Desenvolver uma arquitetura de Geração Aumentada por Recuperação Multimodal (MRAG) capaz de consultar materiais de estudo em PDF com precisão, combinando a segmentação de layout e a extração de elementos visuais estruturantes, a fim de mitigar proativamente alucinações semânticas no contexto educacional.

1.1.2 *Objetivos Específicos*

- Projetar pipelines de processamento e indexação multimodal para identificar elementos visuais, como tabelas, gráficos e diagramas, vinculando-os de forma granular à hierarquia do contexto textual correspondente;
- Desenvolver algoritmos de refinamento contextual para selecionar os fragmentos mais relevantes e reduzir ruídos visuais e textuais do material didático antes da etapa de geração da resposta;
- Desenvolver o protótipo de interface web Luminia Reader, concebido como a camada de aplicação cliente responsável por interagir com o motor de dados do EDGAR e renderizar as evidências visuais recuperadas;
- Validar a eficiência e a precisão da arquitetura por meio de testes experimentais, utilizando métricas automatizadas e cenários baseados em materiais didáticos reais para avaliar o equilíbrio entre a acurácia da recuperação e a latência computacional do sistema.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos fundamentais e o panorama tecnológico que sustentam o desenvolvimento deste estudo. Inicialmente, a Seção 2.1 aborda os grandes modelos de linguagem (LLMs) e o impacto das alucinações semânticas no contexto educacional. Em seguida, a Seção 2.2 discute o funcionamento da arquitetura RAG tradicional e suas limitações diante de documentos com layouts complexos. Na sequência, a Seção 2.3 apresenta o paradigma multimodal (MRAG) e o uso de modelos de visão computacional aplicados à análise de documentos. Por fim, a Seção 2.4 analisa as técnicas de segmentação de layout e extração de componentes digitais, estabelecendo os critérios utilizados no processamento de arquivos PDF.

2.1 Grandes modelos de linguagem e alucinações no ensino

A compreensão, interpretação e geração da linguagem humana por computadores constituem alguns dos desafios mais antigos e centrais da Ciência da Computação, especialmente no campo do Processamento de Linguagem Natural (PLN) (Jurafsky e Martin, 2008). Nos últimos anos, essa área passou por avanços significativos com o surgimento dos Grandes Modelos de Linguagem, ou *Large Language Models* (LLMs), que formam a base tecnológica de muitos sistemas conversacionais e geradores de texto atuais (Zhao *et al.*, 2026). Esse avanço foi impulsionado pela arquitetura *Transformer*, introduzida por Vaswani *et al.* (2017), baseada no mecanismo de autoatenção (*self-attention*), que permite ao modelo considerar simultaneamente diferentes partes de um texto. Diferentemente de abordagens sequenciais tradicionais, essa característica favorece a identificação de relações contextuais entre termos, frases e trechos ao longo de um documento.

Por trás da aparente inteligência dessas ferramentas, o funcionamento básico de um LLM baseia-se em processos probabilísticos. Diante de uma pergunta ou comando, o modelo utiliza mecanismos de autoatenção não para consultar uma base de dados estática de informações verificadas, mas para analisar o contexto fornecido na entrada e estimar, token por token, qual é a continuação mais provável para aquela sequência (Tunstall *et al.*, 2022). Como esse processo se apoia em padrões estatísticos aprendidos durante o treinamento, o sistema tende a priorizar a construção de respostas que pareçam naturais e coerentes para quem lê, mesmo que o modelo não possua, por si só, um mecanismo nativo de verificação factual das informações geradas (Wolfram, 2023).

Essa natureza estatística contribui para uma limitação estrutural relevante dos LLMs, conhecida como alucinação semântica. Esse fenômeno ocorre quando a inteligência artificial gera respostas linguisticamente coerentes, mas que apresentam informações falsas, imprecisas ou não fundamentadas. Na literatura técnica, essas falhas costumam ser divididas em duas categorias: alucinações intrínsecas, quando o modelo contradiz ou ignora informações fornecidas pelo próprio usuário no comando; e alucinações extrínsecas, quando o sistema introduz fatos, nomes ou regras que não são sustentados pelas fontes disponíveis (Ji *et al.*, 2023). Esse comportamento pode estar relacionado a inconsistências e vieses presentes nos dados de treinamento, bem como à tendência dos modelos de produzir continuações textuais plausíveis mesmo quando não possuem evidências suficientes para sustentar a resposta (Alansari e Luqman, 2026).

No ambiente de ensino, essa vulnerabilidade técnica assume implicações pedagógicas relevantes, uma vez que o uso de LLMs como tutores individualizados pode estabelecer uma relação de confiança entre o estudante e a ferramenta (Kasneci *et al.*, 2023). Conforme alertam os autores, por estar em processo de aquisição e consolidação de conhecimento, o aluno nem sempre possui o repertório necessário para identificar alucinações sutis, especialmente quando elas aparecem em respostas formuladas com coerência, fluidez e aparente autoridade. Esse cenário, conforme corroborado por Holmes *et al.* (2023), pode induzir o estudante ao erro de maneira pouco perceptível, favorecendo a consolidação de equívocos conceituais e comprometendo a qualidade do processo de aprendizagem.

2.2 Geração aumentada por recuperação tradicional e suas limitações

Como forma de mitigar as alucinações semânticas e ampliar a base de conhecimento dos LLMs sem a necessidade de novos processos custosos de treinamento, a comunidade de inteligência artificial desenvolveu o conceito de Geração Aumentada por Recuperação (RAG) (Lewis *et al.*, 2020). Em sua abordagem tradicional, também conhecida como RAG linear ou ingênua (*Naive RAG*), esse paradigma é descrito por Gao *et al.* (2023) como a integração entre um mecanismo de busca e um modelo gerador. Nesse fluxo, os documentos didáticos em PDF são inicialmente convertidos em conteúdo textual e segmentados em blocos menores, por meio da técnica de *chunking*. Em seguida, esses fragmentos são transformados em vetores numéricos de alta dimensão, chamados de *embeddings*, que são indexados e armazenados em um banco de dados vetorial especializado.

A dinâmica de consulta desse ecossistema ocorre em tempo de execução, a partir

da interação do usuário. Nesse momento, a pergunta submetida é processada pelo mesmo modelo de conversão utilizado na etapa de indexação, gerando um vetor de busca. Conforme detalhado por Tunstall *et al.* (2022), o sistema executa uma busca vetorial no banco de dados por meio de cálculos de proximidade, como a similaridade de cosseno, identificando os blocos de texto cujo contexto apresenta maior alinhamento com a dúvida enviada. Em seguida, os fragmentos recuperados são inseridos no *prompt* de entrada do LLM, servindo como uma base de conhecimento complementar. Dessa forma, de acordo com o paradigma proposto por Lewis *et al.* (2020), o modelo gerador passa a construir a resposta com apoio em informações previamente recuperadas, em vez de depender apenas dos padrões aprendidos durante seu treinamento, o que contribui para reduzir a ocorrência de alucinações.

Apesar do bom desempenho dessa abordagem em textos corridos e lineares, o RAG tradicional apresenta limitações estruturais quando aplicado a documentos com layout complexo, como livros didáticos e materiais de estudo em formato PDF. Um dos principais desafios está na perda ou simplificação de elementos não textuais, uma vez que tabelas, gráficos, infográficos e diagramas explicativos nem sempre são adequadamente preservados por extratores de texto convencionais, limitando o acesso do LLM a informações visuais relevantes para o aprendizado (Faysse *et al.*, 2025). Além disso, a segmentação do documento em blocos de tamanho fixo pode comprometer a ordem lógica da informação. Em materiais educacionais, é comum que a explicação teórica esteja posicionada ao lado de uma imagem, associada a uma tabela ou distribuída em caixas de destaque. Entretanto, a leitura predominantemente linear do RAG tradicional tende a desconsiderar parte dessa hierarquia visual, podendo misturar fragmentos desconexos, gerar ruídos e comprometer a qualidade do contexto fornecido ao modelo de linguagem (Gao *et al.*, 2023).

2.3 Geração aumentada por recuperação multimodal e modelos de visão

Para superar parte das limitações do RAG tradicional na interpretação de layouts complexos, a área de inteligência artificial tem avançado em direção à Geração Aumentada por Recuperação Multimodal (MRAG) (Mei *et al.*, 2025). A principal contribuição desse paradigma está na capacidade de alinhar diferentes modalidades de dados, como texto e imagem, em um mesmo espaço vetorial. Sob essa perspectiva, o sistema passa a tratar o material didático não apenas como uma sequência linear de texto, mas também a partir de suas representações visuais e estruturais. Isso permite correlacionar semanticamente uma dúvida textual submetida por um

estudante a elementos visuais correspondentes, como gráficos, tabelas ou diagramas, ampliando a relevância desses componentes no processo de recuperação da informação (Mei *et al.*, 2025).

Essa abordagem foi viabilizada pelo avanço dos modelos de linguagem e visão (*Vision-Language Models* – VLMs), os quais, conforme discutido na literatura recente (Yin *et al.*, 2024), podem reduzir a dependência de intermediários tradicionais, como os sistemas de reconhecimento óptico de caracteres (OCR), ao processarem diretamente as representações visuais das páginas dos documentos. Nesse contexto, a arquitetura *ColPali*, introduzida por Faysse *et al.* (2025), representa um avanço relevante ao aplicar o conceito de interação tardia (*Late Interaction*) à busca documental. Segundo os autores, em vez de compactar uma página inteira em um único vetor, essa estratégia gera múltiplos *embeddings* associados a diferentes regiões da imagem, permitindo que o mecanismo considere detalhes visuais e textuais de forma mais granular. Com isso, torna-se possível preservar melhor informações presentes em tabelas complexas, fórmulas matemáticas e infográficos, favorecendo uma recuperação documental com maior fidelidade semântica.

Apesar dos avanços no mapeamento visual de documentos, as implementações atuais de MRAG ainda apresentam desafios técnicos relacionados ao ruído contextual. Em sistemas baseados no *ColPali*, é comum que a captura da página inteira seja recuperada e enviada como contexto para o LLM gerar a resposta. Com isso, o modelo gerador pode receber informações pouco relevantes presentes na mesma página, como cabeçalhos, rodapés, números de página e parágrafos associados a assuntos adjacentes (Yun *et al.*, 2025). Esse excesso de dados visuais pode ocupar parte da janela de contexto da inteligência artificial e reduzir a precisão do processo de geração, ampliando a possibilidade de ocorrência de alucinações semânticas (Liu *et al.*, 2025). Portanto, torna-se necessário desenvolver estratégias de engenharia voltadas ao isolamento granular dos componentes visuais relevantes, de modo a refinar o contexto antes da etapa de geração.

2.4 Segmentação de layout e processamento de documentos

Para enfrentar o problema do ruído contextual gerado pela captura de páginas inteiras, a engenharia de software e a visão computacional recorrem às técnicas de análise de layout de documentos (*Document Layout Analysis* – DLA). Essa subárea investiga métodos capazes de identificar a estrutura geométrica e a organização lógica de um arquivo digital (Zhong *et al.*, 2019). Em vez de tratar o documento PDF apenas como uma sequência linear de caracteres

ou como uma imagem única e indivisível, os modelos de DLA analisam a página para detectar e delimitar seus componentes estruturais por meio de caixas envolventes, conhecidas como *bounding boxes*. Esse mapeamento automático permite estimar as coordenadas bidimensionais de cada bloco de informação, segmentando o arquivo em componentes lógicos, como títulos, parágrafos, tabelas, figuras e listas (Zhong *et al.*, 2019).

O avanço na precisão dessa segmentação foi impulsionado pelo surgimento de modelos de aprendizado profundo voltados à compreensão conjunta de texto, imagem e layout, como a família *LayoutLM*. A arquitetura proposta por Xu *et al.* (2020) demonstrou a importância de processar o conteúdo textual em associação direta com sua posição espacial na página, superando limitações de abordagens que analisavam texto e estrutura visual de forma separada. Esse paradigma foi ampliado no *LayoutLMv3*, apresentado por Huang *et al.* (2022), por meio da unificação do aprendizado multimodal a partir de objetivos de pré-treinamento que consideram simultaneamente texto, imagem e geometria do layout. Como resultado, esse tipo de modelagem favorece a classificação dos blocos detectados e oferece suporte técnico para que sistemas de processamento documental diferenciem elementos estruturais secundários, como cabeçalhos e rodapés, de componentes com maior relevância informacional e pedagógica, como tabelas, gráficos e caixas de texto explicativas.

Uma vez identificadas e classificadas as coordenadas estruturais do documento, torna-se possível aplicar um processamento voltado à filtragem granular dos dados. A partir da localização do elemento relevante, estimada pelos modelos de DLA, viabiliza-se a execução de operações de recorte digital (*cropping*) para isolar o bloco de interesse e reduzir ruídos visuais periféricos, especialmente em documentos com layouts complexos (Zhong *et al.*, 2019). Esse processo de refino e curadoria contribui para diminuir a inserção de informações pouco relevantes na janela de contexto do modelo gerador, uma etapa importante, visto que o excesso de ruído textual e visual pode prejudicar a capacidade de raciocínio e a acurácia dos modelos de linguagem (Liu *et al.*, 2024; Liu *et al.*, 2025). Desse modo, a literatura indica que a integração entre análise visual avançada e segmentação estrutural pode favorecer a fidelidade da recuperação e contribuir para a mitigação de alucinações conceituais em sistemas de busca documental (Gao *et al.*, 2023).

3 TRABALHOS RELACIONADOS

Neste capítulo, são apresentadas pesquisas recentes que abordam o problema da recuperação multimodal em documentos complexos, destacando seus pontos de convergência com a presente proposta, bem como as limitações que motivam o desenvolvimento do EDGAR.

3.1 ColPali: Efficient Document Retrieval with Vision Language Models

Faysse *et al.* (2025) propõem o *ColPali*, uma arquitetura de recuperação de documentos que substitui os tradicionais *pipelines* de extração textual por um modelo de linguagem e visão (VLM) capaz de indexar páginas inteiras como representações visuais. O sistema opera por meio de um mecanismo de interação tardia (*late interaction*), que compara vetores associados a *patches* visuais da página com o vetor da consulta do usuário. Com isso, a abordagem reduz a dependência de OCR e diminui o custo de indexação. Os resultados apresentados pelos autores indicam desempenho competitivo em *benchmarks* de recuperação de documentos com *layouts* complexos, incluindo tabelas e infográficos.

Em termos de convergência técnica, o EDGAR adota o paradigma de indexação baseado em Modelos de Linguagem e Visão (VLM), explorado pelo *ColPali*, ao empregar representações visuais em sua camada macro para capturar a semântica do *layout* sem depender exclusivamente da linearização do texto. Contudo, enquanto o *ColPali* concentra seu fluxo operacional na recuperação de páginas completas, o que pode introduzir ruído visual periférico e reduzir a precisão do contexto fornecido ao modelo gerador (Yun *et al.*, 2025), o EDGAR amplia essa base ao associar a indexação macro a um *pipeline* de granularidade fina. Por meio da análise de layout de documentos (DLA) e do isolamento geométrico de blocos, o presente trabalho segmenta e refina o contexto didático em unidades menores, como parágrafos, tabelas e figuras. Dessa forma, a arquitetura proposta busca atender à necessidade de maior especificidade no domínio educacional, preservando o elo pedagógico entre a explicação teórica e o elemento visual correspondente.

3.2 LILaC: Late Interacting in Layered Component Graph for Open-domain Multimodal Multihop Retrieval

Yun *et al.* (2025) apresentam o LILaC, um *framework* de recuperação multimodal que estrutura documentos como grafos de componentes em camadas, interligando explicitamente

parágrafos, tabelas e imagens por meio de arestas semânticas e estruturais. Essa representação em grafo permite que o sistema realize consultas que exigem o cruzamento de informações distribuídas em múltiplas páginas, alcançando alta precisão em tarefas de recuperação multimodal multi-salto (*multihop*) em domínio aberto.

A principal convergência entre o EDGAR e o LILaC está na fragmentação estrutural do documento em seus componentes constitutivos, mapeando de forma explícita a relação entre blocos textuais e elementos visuais para preservar a integridade do contexto original. Contudo, as arquiteturas diferem quanto à complexidade algorítmica e à estratégia de modelagem dessas relações. Enquanto o LILaC estabelece essa interligação por meio de grafos dinâmicos em camadas e requer a decomposição de consultas com apoio de LLMs, o que aumenta a carga computacional e a latência no fluxo síncrono (Yun *et al.*, 2025), o EDGAR propõe uma alternativa voltada à leveza do *pipeline*. A arquitetura proposta busca preservar a hierarquia semântica e pedagógica do material didático por meio de uma indexação híbrida, vinculando os recortes geométricos diretamente aos metadados dos vetores no fluxo *offline*. Essa decisão de design contribui para fornecer densidade contextual ao modelo gerador, favorecendo a mitigação de alucinações semânticas sem comprometer a baixa latência e a responsividade esperadas na interface do Luminia Reader. Além disso, o EDGAR especializa-se no domínio educacional e em suas particularidades estruturais, diferentemente do LILaC, que é orientado a cenários de recuperação multimodal em domínio aberto.

3.3 SLEUTH: Resolving Evidence Sparsity via Agentic Context Engineering for Long-Document Understanding

Liu *et al.* (2025) propõem o SLEUTH, um *framework* baseado em engenharia de contexto agêntica para a compreensão de documentos longos. O sistema emprega múltiplos agentes de inteligência artificial colaborativos que refinam iterativamente a busca por evidências esparsas ao longo do documento, avaliando a complexidade das consultas, extraindo pistas textuais e visuais e consolidando os fragmentos recuperados em um contexto coerente para o modelo gerador. Essa abordagem demonstrou resultados expressivos em tarefas de compreensão que exigem raciocínio sobre evidências distribuídas em documentos extensos.

O presente trabalho aproxima-se do SLEUTH ao empregar a engenharia de contexto como estratégia para refinar as evidências fornecidas ao modelo gerador, priorizando a curadoria dos fragmentos recuperados em vez da simples inserção de dados brutos. Contudo, as soluções

diferem quanto à temporalidade e à natureza computacional dessa curadoria. Enquanto o SLEUTH opera de forma reativa e dinâmica no fluxo síncrono (*online*), delegando a filtragem contextual a uma infraestrutura iterativa baseada em múltiplos agentes autônomos, o que pode resultar em maior latência e custo computacional por consulta, o EDGAR trata esse problema como uma etapa de engenharia estrutural integrada ao *pipeline* assíncrono (*offline*). Ao refinar o contexto previamente por meio da análise de layout e do isolamento geométrico de blocos, o presente trabalho busca fornecer ao modelo gerador um fragmento informacional mais denso e focado. Essa decisão arquitetural reduz a necessidade de orquestrações agênticas em tempo de execução, favorecendo a baixa latência e a responsividade necessárias para a integração prática do ecossistema ao leitor *web* Luminia Reader.

3.4 Análise Comparativa

A Tabela 1 sintetiza os principais eixos de diferenciação entre os trabalhos relacionados e a arquitetura proposta neste estudo. Os critérios de comparação foram selecionados com base nas dimensões mais relevantes para o domínio educacional: a precisão da recuperação, o custo computacional associado e a capacidade de lidar com a estrutura multimodal e pedagógica dos materiais didáticos em PDF.

Tabela 1 – Análise comparativa dos trabalhos relacionados e o presente trabalho.

Critério	ColPali	LILaC	SLEUTH	EDGAR
Granularidade de recuperação	Página inteira	Componente via grafo	Trecho por agente	Componente isolado
Custo computacional	Baixo	Alto	Alto	Baixo
Suporte a elementos visuais	Sim	Sim	Sim	Sim
Preserva relações entre componentes	Não	Sim	Parcial	Sim
Orquestração de múltiplos agentes	Não	Não	Sim	Não
Mitigação proativa de alucinações	Não	Não	Sim (Síncrona)	Sim (Assíncrona)
Foco em domínio educacional	Não	Não	Não	Sim
Requer OCR	Não	Sim	Não	Sim

Fonte: Elaborado pelo autor.

A análise evidencia que, embora os trabalhos relacionados apresentem contribuições relevantes para a recuperação multimodal, eles não conciliam simultaneamente baixo custo computacional, granularidade fina de recuperação e sensibilidade à estrutura pedagógica dos documentos. O ColPali, apesar de sua eficiência, opera em granularidade de página inteira, o que pode introduzir ruído visual no contexto fornecido ao modelo. O LILaC e o SLEUTH alcançam maior precisão em seus respectivos cenários de avaliação, porém dependem de arquiteturas computacionalmente mais intensivas, cuja latência acumulada pode comprometer a interatividade

em tempo real exigida por um protótipo de leitura web. O EDGAR propõe-se a ocupar essa lacuna ao combinar recuperação em nível de componente isolado, baixo custo computacional e curadoria estrutural do contexto, características orientadas às demandas de validação do sistema proposto.

4 METODOLOGIA

Este capítulo apresenta a abordagem metodológica adotada para a concepção e o design estrutural do EDGAR, detalhando os princípios de engenharia de software e os fluxos de dados que regem o sistema. A arquitetura proposta foi desenvolvida para solucionar o problema da recuperação de informações multimodais em nível de granularidade fina, atuando diretamente como o motor de processamento em segundo plano (*back-end*) para o protótipo de leitura web Luminia Reader. Ao longo das próximas seções, são descritas as especificações técnicas de cada fase do pipeline, divididas entre rotinas assíncronas de preparação documental e rotinas síncronas de atendimento a consultas, bem como o planejamento experimental desenhado para a validação científica da hipótese deste trabalho.

4.1 Visão geral e premissas arquiteturais do sistema

As premissas arquiteturais que norteiam o desenvolvimento do EDGAR baseiam-se na criação de um ecossistema livre de treinamento (*training-free*). Em vez de demandar processos computacionalmente exaustivos de ajuste fino (*fine-tuning*) ou o treinamento do zero de redes neurais profundas, o EDGAR foi projetado estritamente como um pipeline avançado de engenharia de dados. O sistema capitaliza a capacidade de generalização de modelos prontos da literatura (*off-the-shelf*), orquestrando-os de maneira sinérgica por meio de inferência pura e aprendizado em contexto (*in-context learning*). Essa escolha de design permite focar na estruturação e na limpeza do contexto visual e textual entregue aos modelos de linguagem, mitigando alucinações por meio da precisão algorítmica do pipeline e não pelo aumento do tamanho ou do treinamento da rede.

Para viabilizar a usabilidade prática e mitigar o impacto do processamento pesado no dispositivo do usuário final, o sistema adota o paradigma arquitetural cliente-servidor, dividindo suas responsabilidades em duas camadas interdependentes:


- **Frontend (Luminia Reader Web):** Consiste em uma aplicação baseada na web, desenvolvida para rodar diretamente no navegador do estudante. Suas principais atribuições envolvem a renderização fluida do arquivo PDF, a captura da dúvida textual digitada pelo usuário e a exibição da resposta final gerada pela inteligência artificial. Adicionalmente, por operar de forma integrada ao motor de dados, a interface é capaz de destacar visualmente ou abrir componentes em tela contendo o recorte geométrico exato utilizado como

evidência para sanar a dúvida acadêmica.

- **Backend (Servidor EDGAR):** Centraliza toda a inteligência computacional e os modelos de visão e linguagem da arquitetura. O servidor é responsável por receber os documentos, gerenciar os motores de análise de layout, calcular as coordenadas geométricas, realizar o isolamento físico dos blocos didáticos, gerir o banco de dados vetorial e coordenar as chamadas externas de inferência para a geração textual.

Uma decisão crítica na engenharia do EDGAR é a separação temporal do ciclo de vida dos dados em dois fluxos operacionais distintos: o processamento assíncrono (*offline*) e o processamento síncrono (*online*). As tarefas de maior custo computacional, como a conversão de páginas em imagens, a execução do modelo de análise de layout (DLA), o cálculo de caixas envolventes, o recorte preciso dos elementos e a extração localizada de texto via OCR, ocorrem na fase *offline*, executada uma única vez no momento em que o documento é ingerido pelo servidor. Essa estratégia garante que, no fluxo *online* (tempo de consulta), o servidor precise apenas realizar uma varredura ágil nos índices visual e vetorial pré-calculados para recuperar a evidência e disparar o modelo gerador, garantindo a baixa latência e a alta responsividade necessárias para uma aplicação de leitura em tempo real. A topologia completa dessa infraestrutura, ilustrando a divisão de responsabilidades cliente-servidor e o acoplamento das sete fases consecutivas do ecossistema, encontra-se mapeada na Figura 1.

Figura 1 – Fluxograma detalhado do pipeline de dados da arquitetura EDGAR.



Fonte: Elaborado pelo autor.

4.2 O pipeline de ingestão e indexação (fluxo offline)

O pipeline de ingestão e indexação constitui a espinha dorsal assíncrona da arquitetura EDGAR, sendo o responsável por transformar documentos brutos e não estruturados em uma base de conhecimento multimodal de granularidade fina. Este fluxo foi projetado para ser executado em segundo plano, disparado imediatamente após o upload de um arquivo PDF pelo estudante na interface do Luminia Reader. O objetivo central deste pipeline é processar e catalogar previamente os materiais didáticos, eliminando a necessidade de processamentos pesados de visão computacional durante a fase de consulta em tempo real. O fluxo offline é composto por cinco fases consecutivas e interdependentes.

4.2.1 Fase 1: Unificação visual e normalização de entrada

A etapa inicial do pipeline dedica-se à padronização e à resolução de incompatibilidades estruturais nativas dos arquivos digitais. Na literatura de recuperação de documentos, materiais didáticos costumam apresentar-se sob duas formas distintas: PDFs digitais originais,

que possuem uma camada de texto vetorial selecionável, e PDFs escaneados, que consistem em agregações de imagens digitalizadas sem metadados textuais acessíveis. Para anular essa disparidade e garantir que as fases subsequentes operem de forma homogênea, o EDGAR converte todas as páginas do documento em matrizes de imagem de alta resolução (renderizadas em uma densidade mínima de 300 DPI). Essa abordagem de unificação visual estabelece uma modalidade de entrada única e normalizada para o sistema, permitindo que materiais antigos, apostilas escaneadas ou livros digitais modernos passem exatamente pelo mesmo tratamento algorítmico.

4.2.2 Fase 2: *Análise de layout de documentos (DLA)*

Com as páginas do documento convertidas em imagens padronizadas, o servidor aciona o módulo de Análise de Layout de Documentos (*Document Layout Analysis* - DLA). Este módulo utiliza um modelo de visão computacional especializado na identificação da sintaxe visual de materiais acadêmicos. O algoritmo varre a imagem de cada página para detectar, classificar e delimitar os componentes pedagógicos e estruturais presentes. O modelo foi projetado para segmentar a folha em classes predefinidas, discriminando parágrafos de texto corrido, tabelas, figuras, legendas, fórmulas matemáticas isoladas e caixas de destaque conceitual. O resultado desta fase é a geração de um conjunto de matrizes numéricas contendo as coordenadas geométricas exatas — denominadas caixas envolventes (*bounding boxes*) e representadas pelos pontos cartesianos de valores mínimos e máximos de X e Y — de cada elemento identificado, estabelecendo a fundação para a granularidade fina do sistema.

4.2.3 Fase 3: *Isolamento geométrico de componentes (cropping)*

A terceira fase do pipeline executa o desbaste e a purificação dos dados por meio do isolamento geométrico dos componentes detectados na etapa anterior. Utilizando os mapeamentos numéricos das caixas envolventes, o sistema realiza uma operação de recorte digital direcionado diretamente sobre os pixels da imagem da página original. Este procedimento isola fisicamente cada elemento estrutural relevantes do restante do documento. A importância de engenharia desta fase reside na eliminação sistemática de ruídos contextuais adjacentes e informações marginais, tais como cabeçalhos institucionais, números de paginação, notas de rodapé ou textos de tópicos paralelos que dividem a mesma folha. Cada sub-região recortada passa a figurar como a unidade mínima de conhecimento do ecossistema EDGAR, preservando

estritamente o elo pedagógico nativo entre o conteúdo textual e as ilustrações associadas.

4.2.4 Fase 4: Extração localizada de texto (OCR seletivo)

Uma vez obtidos os blocos geométricos isolados e limpos, o pipeline procede para a extração do conteúdo textual de maneira estritamente localizada e direcionada. O EDGAR opera de forma híbrida nesta fase para otimizar os recursos computacionais do servidor. Se o componente didático for oriundo de um PDF digital original, o sistema realiza uma varredura direta nos metadados do arquivo para extrair os caracteres contidos exatamente dentro daquelas coordenadas geográficas, dispensando o processamento de imagem. Caso o componente pertença a um documento escaneado, o motor de Reconhecimento Óptico de Caracteres (*Optical Character Recognition* - OCR) é ativado de forma restrita sobre a imagem individual do recorte purificado. Essa abordagem localizada mitiga o erro clássico de corrupção, quebra de tabelas e desalinhamento de leitura que costuma ocorrer quando algoritmos de OCR tentam processar páginas inteiras com layouts complexos de múltiplas colunas.

4.2.5 Fase 5: Vetorização e indexação multimodal híbrida

A fase final do fluxo offline consolida os dados estruturados e os prepara para o acesso imediato em tempo de execução. Os textos puros extraídos e purificados na fase anterior são submetidos a um modelo de embutimento (*embeddings*) para serem transformados em vetores densos que capturam o seu significado semântico. Esses vetores são armazenados em um banco de dados vetorial especializado, onde cada registro é indexado juntamente com os seus metadados de origem, incluindo o identificador do documento, o número da página original e as coordenadas geométricas do bloco. Paralelamente, as imagens completas das páginas geradas na Fase 1 são indexadas de forma independente por um modelo de linguagem e visão (*Vision-Language Model* - VLM). Esta estratégia de indexação híbrida em dois níveis encerra a preparação prévia do material didático, deixando o conhecimento estruturado de forma macro (visual) e micro (vetorial) para responder às consultas.

4.3 O pipeline de recuperação e geração (fluxo online)

O pipeline de recuperação e geração opera no fluxo síncrono da arquitetura EDGAR, atuando em tempo real assim que o estudante interage com a interface do Luminia Reader. Ao

contrário do processamento offline, que lida com a estruturação em massa dos dados, o fluxo online é otimizado para baixa latência e alta precisão contextual. Esta etapa é responsável por receber a dúvida do usuário, vasculhar a base de conhecimento estruturada, isolar as evidências e orquestrar a resposta do modelo gerador de 8B parâmetros de maneira totalmente purificada. Este fluxo divide-se em duas fases finais essenciais.

4.3.1 Fase 6: Recuperação multimodal híbrida e casamento de coordenadas

O fluxo inicia-se no momento em que o estudante insere uma dúvida em linguagem natural na interface cliente. A requisição de texto é encaminhada ao servidor EDGAR, onde é convertida instantaneamente em um vetor denso por meio do mesmo modelo de embutimento utilizado na fase de indexação. O sistema realiza uma busca por similaridade de cosseno no banco de dados vetorial para identificar as unidades mínimas de conhecimento mais aderentes à intenção do usuário. O diferencial da arquitetura nesta fase consiste no casamento de índices: ao localizar o vetor textual semanticamente relevante, o motor recupera simultaneamente, por meio dos metadados associados, o identificador do documento, o número exato da página e as coordenadas cartesianas da caixa envolvente correspondente ao elemento visual ou textual isolado no fluxo offline.

4.3.2 Fase 7: Engenharia de contexto purificado e inferência


Com os componentes mais relevantes localizados, o EDGAR ativa o módulo de engenharia de contexto. Em vez de injetar páginas completas ou janelas de texto lineares que carregam ruídos periféricos do layout, o sistema monta um prompt densamente povoado apenas com as unidades de informação isoladas. O contexto é estruturado associando o texto purificado do bloco e, quando aplicável, o recorte geométrico da imagem da tabela ou gráfico vinculado. Esse pacote de evidências limpas é entregue ao modelo de linguagem de 8B parâmetros para a inferência. Como a entrada foi desprovida de distrações estruturais ou dados marginais, o modelo de pequeno porte consegue concentrar sua capacidade de atenção estritamente nos fatos contidos no material didático, gerando uma resposta precisa e mitigando de forma proativa a ocorrência de alucinações semânticas.

4.3.3 Interação cliente-servidor e renderização de evidências

A finalização do fluxo online consolida a integração entre o motor back-end e a interface front-end do Luminia Reader. Após a geração da resposta pelo modelo de linguagem, o servidor EDGAR encapsula a saída textual juntamente com os metadados geográficos das evidências utilizadas (número da página e coordenadas de pixels). Ao receber o pacote de dados via payload JSON, a aplicação cliente renderiza a resposta na aba lateral de tutoria e, simultaneamente, utiliza as coordenadas espaciais para desenhar uma camada visual de destaque diretamente sobre o componente correspondente no leitor de PDF do estudante. Esse mecanismo fecha o elo pedagógico, permitindo que o usuário verifique visualmente a origem exata da informação fornecida pela inteligência artificial.

Para clarificar a dinâmica temporal e a troca de mensagens desse processo síncrono, a Figura 2 ilustra o diagrama de sequência correspondente. Como pode ser observado na disposição dos componentes, a comunicação estende-se horizontalmente a partir do gatilho inicial disparado na interface cliente, trafegando linearmente pela API do servidor, pela varredura no banco de dados vetorial e pela inferência no modelo de linguagem. O fluxo encerra-se com o retorno do payload estruturado para a renderização final na tela do usuário, evidenciando a ausência de loops agênticos complexos e justificando o comportamento de baixa latência do ecossistema.

Figura 2 – Diagrama de sequência da interação cliente-servidor no fluxo online.



Fonte: elaborado pelo autor (2026).

4.4 Validação

O plano de validação da arquitetura EDGAR fundamenta-se em um protocolo estruturado para mensurar a eficiência computacional e a precisão semântica do ecossistema. O objetivo deste delineamento é demonstrar empiricamente a hipótese do trabalho: que a

purificação contextual em granularidade fina viabiliza a operação de modelos de linguagem compactos (8B parâmetros) sob restrições de infraestrutura, mitigando alucinações semânticas sem penalizar excessivamente a latência síncrona do sistema.

4.4.1 Ambiente de Execução e Infraestrutura Computacional

Para viabilizar a execução dos testes sob restrições locais de hardware, a infraestrutura de back-end da arquitetura EDGAR será hospedada de forma remota em uma instância de máquina virtual provisionada em ambiente de computação em nuvem. Essa abordagem isola o processamento intensivo exigido pelo modelo de linguagem de 8B parâmetros, que operará em um contêiner Docker configurado na máquina virtual com acesso dedicado a uma unidade de processamento gráfico (GPU) dotada de, no mínimo, 24 GB de memória de vídeo (VRAM). Em contrapartida, a aplicação cliente Luminia Reader será executada de forma nativa no navegador web da máquina local do usuário. Essa arquitetura distribuída permite avaliar o comportamento real do ecossistema, replicando um cenário de produção em que a sobrecarga computacional da inteligência artificial é absorvida inteiramente pela infraestrutura virtualizada, mantendo o cliente final leve e responsivo.

4.4.2 Corpus de Avaliação (Dataset Didático)

O pipeline de testes utilizará um conjunto de dados construído a partir de materiais didáticos reais e heterogêneos de nível universitário, com foco em disciplinas das ciências exatas e tecnológicas. O corpus será composto por apresentações de slides convertidas e capítulos de livros didáticos em formato PDF que exibam intencionalmente uma alta densidade de layouts complexos, tais como tabelas comparativas, diagramas de arquitetura, gráficos de dados e equações matemáticas inseridas paralelamente ao texto. A partir desse material, será estruturado um banco de dados de teste contendo perguntas em linguagem natural formuladas para simular dúvidas comuns de estudantes, mapeadas previamente para os blocos exatos que detêm as respostas de correspondência visual e textual.

4.4.3 Métricas e Protocolo de Avaliação

A avaliação do ecossistema será dividida em duas dimensões complementares: o desempenho temporal da engenharia de software e a qualidade da engenharia de dados. A

dimensão temporal será mensurada por meio da Latência de Ponta a Ponta (L_{p2p}), calculada em segundos desde o instante do disparo da requisição no Luminia Reader até o recebimento do payload completo de resposta, subdividida internamente pelo tempo de recuperação vetorial e tempo de geração de tokens (*time-to-first-token*).

A dimensão qualitativa e semântica utilizará a abordagem *LLM-as-a-judge* por meio de métricas automatizadas consagradas na literatura de sistemas de Geração Aumentada por Recuperação. Serão avaliados três indicadores centrais: a Fidelidade Contextual (*Faithfulness*), avaliando se a resposta do modelo apoia-se estritamente nas evidências purificadas fornecidas; a Relevância da Resposta (*Answer Relevance*), medindo a aderência da saída à dúvida inicial do aluno; e a Precisão de Recuperação (*Context Precision*), validando se o motor EDGAR priorizou os blocos corretos nos primeiros rankings da busca híbrida. A Tabela 2 sintetiza a matriz de configuração e as métricas que guiarão o plano experimental.

Tabela 2 – Matriz de configuração da infraestrutura, modelos e métricas experimentais.

Componente	Especificação Técnica	Variável / Métrica de Avaliação
Servidor (VM na Nuvem)	GPU $\geq$ 24 GB VRAM / Docker	Monitoramento de uso de memória de vídeo
Modelo DLA	Redes Neurais para Layout	Tempo de execução do fatiamento (<i>offline</i>)
Modelo de Linguagem	LLM Open-Source de 8B	Taxa de geração de tokens por segundo
Banco Vetorial	Indexação Híbrida Espacial	Similaridade de cosseno de granularidade fina
Desempenho Geral	Fluxo Síncrono Cliente-Servidor	Latência temporal total em segundos (L_{p2p})
Qualidade Semântica	Avaliação Automatizada de RAG	<i>Faithfulness, Answer Relevance, Context Precision</i>

Fonte: elaborado pelo autor.

4.4.4 Cronograma

Nesta subseção, é apresentado o cronograma de atividades planejadas para a continuidade do projeto. O planejamento divide-se entre a escolha do tema, fundamentação e prototipagem da interface conduzidas no âmbito do TCC I, e as etapas práticas de desenvolvimento dos pipelines, integração e testes de validação projetadas para o TCC II.

Tabela 3 – Cronograma.

Atividades	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Escolha do Tema	X									
Revisão Bibliográfica		X								
Especificação Arquitetural		X								
Prototipagem da Interface				X						
Escrita do TCC 1		X	X	X						
Defesa do TCC 1					X					
Desenvolvimento do Pipeline Offline						X				
Desenvolvimento do Pipeline Online							X			
Integração do Ecossistema								X		
Testes de Validação									X	
Escrita do TCC 2								X	X	
Defesa do TCC 2										X

Fonte: Elaborado pelo autor.

5 RESULTADOS PRELIMINARES

5.1 Resultados do Motor de Dados (EDGAR)

- **Segmentação e Análise de Layout de Documentos (DLA):** Apresentação de uma figura demonstrando a aplicação prática do modelo de visão computacional sobre uma página de um artigo ou livro didático, evidenciando os delimitadores espaciais (*bounding boxes*) isolando blocos de texto, tabelas e elementos gráficos.
- **Extração e Estruturação de Metadados:** Exibição do fragmento de código contendo o *payload* JSON gerado pelo pipeline *offline*, comprovando a capacidade do EDGAR de indexar o conteúdo textual associado às suas respectivas coordenadas geométricas de pixels e numeração de páginas.

5.2 Protótipo da Interface Cliente (Luminia Reader)

- **Ambiente Integrado de Estudos:** Planejamento de figura contendo o protótipo de alta fidelidade da tela principal do leitor de PDF com o painel lateral de tutoria por IA de dados simulados.
- **Mecanismo de Destaque Geométrico:** Planejamento de figura demonstrando o comportamento visual da interface ao interpretar as coordenadas do JSON, aplicando o sombreamento colorido sobre o componente correspondente no documento para guiar o estudante.

6 CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho apresentou a concepção inicial do EDGAR, uma arquitetura de Geração Aumentada por Recuperação Multimodal voltada à consulta de documentos didáticos em PDF. A proposta foi motivada pela necessidade de tornar mais confiável a interação entre estudantes e sistemas baseados em modelos de linguagem, especialmente em cenários nos quais o conteúdo consultado envolve não apenas texto linear, mas também tabelas, diagramas, gráficos e demais elementos visuais relevantes para a compreensão do material.

No desenvolvimento do TCC I, foram consolidados os fundamentos teóricos relacionados a LLMs, alucinações semânticas, RAG, MRAG e análise de layout de documentos, além da análise de trabalhos recentes que evidenciam limitações ainda existentes na recuperação multimodal. A partir dessa base, foi definida a arquitetura do EDGAR, estruturada em fluxos offline e online, com o objetivo de separar as etapas de maior custo computacional daquelas executadas em tempo de consulta. Essa organização permite que o processamento prévio do documento produza unidades de informação mais específicas, associando conteúdo textual, recortes visuais e metadados geométricos para apoiar a geração de respostas mais contextualizadas.

Como contribuição desta etapa, o trabalho estabelece uma proposta arquitetural orientada à granularidade fina, buscando preservar a relação entre os elementos pedagógicos presentes no documento e reduzir a inserção de ruídos no contexto fornecido ao modelo gerador. Embora a validação experimental ainda esteja prevista para o TCC II, a especificação apresentada fornece a base necessária para a implementação do motor EDGAR e sua integração ao Luminia Reader, interface web concebida para permitir a consulta interativa ao material didático e a visualização das evidências utilizadas na resposta.

Como trabalhos futuros, pretende-se implementar os pipelines de ingestão, indexação, recuperação e geração, definir os modelos e ferramentas que comporão a infraestrutura final, integrar o servidor EDGAR à interface Luminia Reader e conduzir os experimentos de validação. Essa avaliação deverá considerar tanto aspectos de desempenho, como latência e custo computacional, quanto aspectos semânticos, como precisão da recuperação, relevância da resposta e fidelidade ao contexto recuperado. Dessa forma, espera-se verificar a viabilidade técnica da arquitetura proposta e seu potencial de apoio a sistemas educacionais baseados em documentos didáticos multimodais.

REFERÊNCIAS

- ALANSARI, A.; LUQMAN, H. Large language models hallucination: A comprehensive survey. **Computer Science Review**, Elsevier, v. 61, p. 100970, 2026.
- FAYSSE, M.; SIBILLE, H.; WU, T.; OMRANI, B.; VIAUD, G.; HUDELLOT, C.; COLOMBO, P. Colpali: Efficient document retrieval with vision language models. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2025. v. 2025, p. 61424–61449.
- GAO, Y.; XIONG, Y.; GAO, X.; JIA, K.; PAN, J.; BI, Y.; DAI, Y.; SUN, J.; WANG, H.; WANG, H. *et al.* Retrieval-augmented generation for large language models: A survey. **arXiv preprint arXiv:2312.10997**, v. 2, n. 1, p. 32, 2023.
- HOLMES, W.; MIAO, F. *et al.* **Guidance for generative AI in education and research**. [S.l.]: Unesco Publishing, 2023.
- HUANG, Y.; LV, T.; CUI, L.; LU, Y.; WEI, F. Layoutlmv3: Pre-training for document ai with unified text and image masking. In: **Proceedings of the 30th ACM international conference on multimedia**. [S.l.: s.n.], 2022. p. 4083–4091.
- JI, Z.; LEE, N.; FRIESKE, R.; YU, T.; SU, D.; XU, Y.; ISHII, E.; BANG, Y. J.; MADOTTO, A.; FUNG, P. Survey of hallucination in natural language generation. **ACM Computing Surveys**, Association for Computing Machinery (ACM), v. 55, n. 12, p. 1–38, mar. 2023. ISSN 1557-7341. Disponível em: <<http://dx.doi.org/10.1145/3571730>>.
- JURAFSKY, D.; MARTIN, J. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition**. [S.l.: s.n.], 2008. v. 2.
- KASNECI, E.; SESSLER, K.; KÜCHEMANN, S.; BANNERT, M.; DEMENTIEVA, D.; FISCHER, F.; GASSER, U.; GROH, G.; GÜNNEMANN, S.; HÜLLERMEIER, E. *et al.* Chatgpt for good? on opportunities and challenges of large language models for education. **Learning and individual differences**, Elsevier, v. 103, p. 102274, 2023.
- LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KÜTTLER, H.; LEWIS, M.; YIH, W.-t.; ROCKTÄSCHEL, T.; RIEDEL, S.; KIELA, D. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: LAROCHELLE, H.; RANZATO, M.; HADSELL, R.; BALCAN, M.; LIN, H. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2020. v. 33, p. 9459–9474. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>.
- LIU, K.; CHEN, Z.; LI, M.; TANG, J.; YANG, D.; ZHANG, L. Resolving evidence sparsity: Agentic context engineering for long-document understanding. **arXiv preprint arXiv:2511.22850**, 2025.
- LIU, N. F.; LIN, K.; HEWITT, J.; PARANJAPE, A.; BEVILACQUA, M.; PETRONI, F.; LIANG, P. Lost in the middle: How language models use long contexts. **Transactions of the association for computational linguistics**, v. 12, p. 157–173, 2024.
- MEI, L.; MO, S.; YANG, Z.; CHEN, C. A survey of multimodal retrieval-augmented generation. **arXiv preprint arXiv:2504.08748**, 2025.

- RASCHKA, S. **Build a large language model (from scratch)**. [S.l.]: Simon and Schuster, 2024.
- TUNSTALL, L.; WERRA, L. von; WOLF, T. **Natural Language Processing with Transformers: Building Language Applications with Hugging Face**. O'Reilly Media, 2022. ISBN 9781098103248. Disponível em: <https://books.google.de/books?id=_0uezgEACAAJ>.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. **Advances in neural information processing systems**, v. 30, 2017.
- WOLFRAM, S. **What Is ChatGPT Doing:... and Why Does It Work?** [S.l.]: Wolfram Media, 2023.
- XU, Y.; LI, M.; CUI, L.; HUANG, S.; WEI, F.; ZHOU, M. Layoutlm: Pre-training of text and layout for document image understanding. In: **Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining**. [S.l.: s.n.], 2020. p. 1192–1200.
- YIN, S.; FU, C.; ZHAO, S.; LI, K.; SUN, X.; XU, T.; CHEN, E. A survey on multimodal large language models. **National Science Review**, Oxford University Press (OUP), v. 11, n. 12, nov. 2024. ISSN 2053-714X. Disponível em: <<http://dx.doi.org/10.1093/nsr/nwae403>>.
- YUN, J.; LEE, D.; HAN, W.-S. Lilac: Late interacting in layered component graph for open-domain multimodal multihop retrieval. In: **Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing**. [S.l.: s.n.], 2025. p. 20551–20570.
- ZHAO, W.; ZHOU, K.; LI, J.; TIANYI, T.; DONG, Z.; HOU, Y.; ZHANG, B.; MIN, Y.; ZHANG, J.; LIU, P.; WANG, X.; DU, Y.; YANG, C.; CHEN, Y.; CHEN, Z.; JIANG, J.; REN, R.; LI, Y.; TANG, X.; WEN, J.-R. A survey of large language models. **Frontiers of Computer Science**, v. 20, 05 2026.
- ZHONG, X.; TANG, J.; YEPES, A. J. Publaynet: largest dataset ever for document layout analysis. In: IEEE. **2019 International conference on document analysis and recognition (ICDAR)**. [S.l.], 2019. p. 1015–1022.