



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS DE QUIXADÁ
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

FRANCISCO EDINALDO DOS SANTOS SILVA

**EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA MRAG DE
GRANULARIDADE FINA VOLTADA PARA DOCUMENTOS DIDÁTICOS EM PDF**

QUIXADÁ

2026

FRANCISCO EDINALDO DOS SANTOS SILVA

EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA MRAG DE
GRANULARIDADE FINA VOLTADA PARA DOCUMENTOS DIDÁTICOS EM PDF

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Campus de Quixadá da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Ciência da Computação.

Orientador: Prof. Dr. Cristiano Bacelar
de Oliveira

QUIXADÁ

2026

FRANCISCO EDINALDO DOS SANTOS SILVA

EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA MRAG DE
GRANULARIDADE FINA VOLTADA PARA DOCUMENTOS DIDÁTICOS EM PDF

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Campus de Quixadá da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Ciência da Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Cristiano Bacelar de Oliveira (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, pelo apoio incondicional e motivo de orgulho, e aos meus amigos, que dividiram e facilitaram essa longa trajetória.

RESUMO

Este trabalho apresenta o desenvolvimento de uma arquitetura denominada EDGAR, baseada em Geração Aumentada por Recuperação Multimodal (MRAG), voltada à consulta de documentos didáticos em PDF. A arquitetura estrutura-se como um *pipeline* de engenharia de dados dividido em fluxos operacionais assíncrono (*offline*) e síncrono (*online*), utilizando modelos de análise de layout de documentos (DLA), extração textual localizada, descrição visual de componentes e indexação vetorial para viabilizar buscas em granularidade fina. Essa abordagem permite isolar componentes textuais e visuais relevantes antes da formulação das respostas, contribuindo para a redução de ruídos contextuais associados à complexidade estrutural de materiais didáticos. Para possibilitar o uso, os testes e a demonstração prática da arquitetura, este trabalho prevê o desenvolvimento do LuminIA Reader, uma aplicação cliente baseada na web destinada à submissão de documentos, ao envio de perguntas e à visualização das respostas e evidências retornadas pelo EDGAR. A avaliação experimental busca verificar a viabilidade técnica da arquitetura ao operar com modelos de código aberto (*open-source*), considerando aspectos como recuperação de evidências, fidelidade das respostas e latência computacional. Como contribuição, o EDGAR propõe uma abordagem sem necessidade de treinamento adicional (*training-free*) para apoiar interações mais rastreáveis entre o estudante e o material didático multimodal.

Palavras-chave: Geração Aumentada por Recuperação; Recuperação multimodal; Visão computacional; Materiais didáticos; Granularidade fina.

LISTA DE FIGURAS

Figura 1 – Visão geral do funcionamento da arquitetura EDGAR.	23
Figura 2 – Diagrama de sequência do fluxo síncrono de recuperação e geração da arquitetura.	34

LISTA DE TABELAS

Tabela 1 – Análise comparativa dos trabalhos relacionados e o presente trabalho.	21
Tabela 2 – Componentes tecnológicos definidos para a arquitetura do presente trabalho e sua camada de aplicação cliente.	24
Tabela 3 – Configurações comparativas previstas para a avaliação experimental.	36
Tabela 4 – Matriz de componentes e métricas previstas para a avaliação experimental. .	38
Tabela 5 – Cronograma de atividades do projeto.	39

SUMÁRIO

1	INTRODUÇÃO	9
1.1	Objetivos	12
<i>1.1.1</i>	<i>Objetivo Geral</i>	<i>12</i>
<i>1.1.2</i>	<i>Objetivos Específicos</i>	<i>12</i>
2	FUNDAMENTAÇÃO TEÓRICA	13
2.1	Grandes modelos de linguagem e alucinações no ensino	13
2.2	Geração aumentada por recuperação tradicional e suas limitações . . .	14
2.3	Geração aumentada por recuperação multimodal e modelos de visão . .	15
2.4	Segmentação de layout e processamento de documentos	16
3	TRABALHOS RELACIONADOS	18
3.1	ColPali: Efficient Document Retrieval with Vision Language Models . .	18
3.2	LILaC: Late Interacting in Layered Component Graph for Open-domain Multimodal Multihop Retrieval	19
3.3	SLEUTH: Resolving Evidence Sparsity via Agentic Context Engineering for Long-Document Understanding	20
3.4	Análise Comparativa	20
4	METODOLOGIA	22
4.1	Visão geral da arquitetura EDGAR	22
4.2	Definição dos componentes tecnológicos	24
<i>4.2.1</i>	<i>Justificativa das tecnologias adotadas</i>	<i>25</i>
4.3	Fluxo assíncrono de ingestão e indexação	28
<i>4.3.1</i>	<i>Fase 1: Unificação visual e normalização de entrada</i>	<i>28</i>
<i>4.3.2</i>	<i>Fase 2: Análise de layout de documentos (DLA)</i>	<i>28</i>
<i>4.3.3</i>	<i>Fase 3: Isolamento geométrico de componentes (cropping)</i>	<i>29</i>
<i>4.3.4</i>	<i>Fase 4: Extração textual localizada (OCR seletivo)</i>	<i>29</i>
<i>4.3.5</i>	<i>Fase 5: Descrição visual de componentes</i>	<i>30</i>
<i>4.3.6</i>	<i>Fase 6: Vetorização e indexação multimodal híbrida</i>	<i>30</i>
4.4	Fluxo síncrono de recuperação e geração	31
<i>4.4.1</i>	<i>Fase 7: Recuperação semântica e associação de evidências</i>	<i>32</i>
<i>4.4.2</i>	<i>Fase 8: Engenharia de contexto e inferência</i>	<i>32</i>

4.4.3	<i>Interação com a aplicação cliente e visualização de evidências</i>	33
4.5	Plano de avaliação experimental	34
4.5.1	<i>Ambiente de execução e infraestrutura computacional</i>	34
4.5.2	<i>Conjunto de documentos e perguntas de avaliação</i>	35
4.5.3	<i>Configurações comparativas de avaliação</i>	36
4.5.4	<i>Métricas e protocolo de avaliação</i>	36
4.6	Cronograma	38
5	RESULTADOS PRELIMINARES	40
5.1	Resultados preliminares da arquitetura EDGAR	40
5.2	Protótipo da aplicação cliente LuminIA Reader	40
6	CONCLUSÕES E TRABALHOS FUTUROS	42
	REFERÊNCIAS	43

1 INTRODUÇÃO

O avanço acelerado da Inteligência Artificial (IA) generativa tem impulsionado transformações profundas no cenário educacional, com os grandes modelos de linguagem (LLMs) emergindo como ferramentas promissoras para mediar a relação entre o estudante e o conhecimento (Kasneci *et al.*, 2023). Aplicações baseadas nesses modelos passaram a ser exploradas em tarefas como tutoria automatizada, sumarização de materiais didáticos e resposta a perguntas sobre conteúdos acadêmicos, abrindo novas possibilidades para o aprendizado assistido por IA. Contudo, apesar da alta capacidade de articulação textual, esses modelos apresentam uma limitação estrutural crítica para o ambiente educacional: a alucinação semântica. Esse fenômeno é caracterizado pela geração de respostas que, embora gramaticalmente fluidas, são factualmente incorretas ou completamente desconectadas das fontes de dados consultadas, o que compromete diretamente a confiabilidade da informação entregue ao estudante (Raschka, 2024).

Para mitigar essa vulnerabilidade e ancorar as respostas em fontes de dados verificáveis, Lewis *et al.* (2020) introduziram a arquitetura de *Retrieval-Augmented Generation* (RAG), uma abordagem que atua como um intermediário que extrai blocos de informação de uma base de conhecimento externa e os injeta no contexto do modelo antes da geração da resposta, garantindo a proveniência dos dados e reduzindo a ocorrência de alucinações. No contexto educacional, essa arquitetura representa um avanço relevante, pois possibilita que sistemas de IA respondam com base no conteúdo real dos materiais didáticos fornecidos pelo próprio estudante ou pela instituição.

Entretanto, o RAG tradicional foi concebido para operar sobre repositórios textuais lineares, o que representa uma limitação significativa diante da natureza dos documentos acadêmicos reais. Conforme apontado por Gao *et al.* (2023), o processamento textual padrão frequentemente fragmenta e corrompe dados semiestruturados presentes em PDFs. Além disso, mecanismos de recuperação baseados puramente em texto mostram-se insuficientes para lidar com documentos cuja transmissão de conhecimento depende de layouts complexos, tabelas, infográficos e diagramas visuais, elementos amplamente presentes em livros didáticos e artigos científicos (Faysse *et al.*, 2025; Yun *et al.*, 2025). Nesse contexto, a evolução para arquiteturas de *Multimodal Retrieval-Augmented Generation* (MRAG) impõe-se como caminho natural, uma vez que a compreensão integral de um documento educacional exige que o motor de busca seja capaz de interpretar simultaneamente as dimensões textuais e visuais que estruturam a informação.

No entanto, apesar dos avanços que a transição para MRAG representa, as soluções

presentes na literatura ainda divergem entre eficiência computacional e precisão granular, não atendendo plenamente às exigências do domínio educacional. Abordagens baseadas puramente em Visão Computacional, como a arquitetura ColPali, proposta por Faysse *et al.* (2025), introduziram a recuperação direta de imagens de páginas inteiras utilizando mecanismos de “*interação tardia*”. Apesar de serem mais rápidas por eliminarem processos custosos de reconhecimento óptico de caracteres (*Optical Character Recognition – OCR*), essas arquiteturas operam em uma granularidade fixa de página, o que frequentemente insere ruído visual irrelevante no contexto do modelo e dilui a precisão em consultas específicas (Yun *et al.*, 2025).

Para contornar esse excesso de ruído e mitigar alucinações, frameworks recentes como o SLEUTH (Liu *et al.*, 2025), empregam múltiplos agentes de IA colaborativos para refinar a busca em documentos longos. Paralelamente, sistemas como o LILaC (Yun *et al.*, 2025) fragmentam o documento em grafos de componentes em camadas para interligar explicitamente parágrafos, tabelas e imagens, alcançando alta precisão em raciocínios que exigem cruzar informações de múltiplas páginas. Contudo, tanto a orquestração de múltiplos agentes quanto a construção de grafos complexos combinada com a decomposição de consultas via LLMs impõem uma elevada carga computacional e aumentam a latência do sistema (Liu *et al.*, 2025; Yun *et al.*, 2025).

Além disso, o foco primário dessas tecnologias tem sido o domínio aberto, científico ou administrativo (Liu *et al.*, 2025; Yun *et al.*, 2025), negligenciando a estrutura pedagógica única, expressa na relação direta entre teoria, exercícios e diagramas explicativos, intrínseca aos materiais didáticos.

O presente trabalho, intitulado EDGAR, propõe o desenvolvimento de uma arquitetura de Geração Aumentada por Recuperação Multimodal (MRAG), concebida para o contexto educacional. O sistema tem como objetivo indexar e recuperar, com alta precisão e baixo custo computacional, tanto o conteúdo textual quanto a estrutura visual de documentos didáticos complexos, incluindo tabelas, gráficos e diagramas. Em vez de depender de uma estrutura custosa baseada em múltiplos agentes ou da modelagem de grafos genéricos de domínio aberto, a solução introduz um método de indexação voltado à compreensão da hierarquia semântica do material de estudo. Ao isolar e recuperar o recorte visual exato associado ao seu respectivo contexto textual, a arquitetura busca fornecer ao modelo gerador um bloco de informação mais consistente, contextualizado e com menor presença de ruídos.

Dessa maneira, este projeto apresenta contribuições relevantes para a promoção da

segurança, da veracidade e da confiabilidade da informação no processo de ensino-aprendizagem mediado por IA, uma vez que a ocorrência de alucinações compromete diretamente o propósito educacional da tecnologia. Nesse sentido, a relevância do trabalho está relacionada à preservação do elo pedagógico entre elementos textuais e visuais, mantendo-os alinhados à estrutura original do conteúdo. Para possibilitar o uso, a demonstração e a avaliação prática da arquitetura proposta, este trabalho prevê o desenvolvimento do LuminIA Reader, uma aplicação cliente baseada na web concebida para permitir a submissão de documentos, o envio de perguntas e a visualização das respostas e evidências retornadas pela arquitetura. Como resultado, a abordagem busca mitigar falhas de forma proativa por meio da curadoria estrutural do contexto, reduzindo ruídos visuais e textuais antes da etapa de geração da resposta pelo modelo de linguagem.

Para alcançar os objetivos propostos, o desenvolvimento da arquitetura EDGAR seguirá um percurso metodológico organizado em etapas de especificação arquitetural, modelagem dos *pipelines* de dados, definição dos componentes tecnológicos e planejamento da avaliação experimental. Os recursos previstos baseiam-se no uso de ferramentas e modelos de código aberto (*open-source*), incluindo redes neurais pré-treinadas para análise de layout, mecanismos de extração textual, modelos de descrição visual e bancos de dados vetoriais voltados à indexação e recuperação semântica. Essa escolha busca favorecer a reprodutibilidade da pesquisa e a viabilidade de implementação em ambientes computacionais acessíveis, com apoio de infraestrutura remota para as etapas de maior custo computacional.

A avaliação da arquitetura proposta será conduzida por meio de um plano experimental destinado a analisar tanto o desempenho computacional dos fluxos de processamento quanto a qualidade semântica das respostas geradas. Serão consideradas métricas relacionadas à latência no fluxo síncrono, ao tempo de processamento no fluxo assíncrono, à precisão na recuperação de evidências, à relevância das respostas e à fidelidade ao contexto recuperado. Como limitação deste estágio da pesquisa, o escopo restringe-se à análise da arquitetura EDGAR em documentos de domínio educacional normalizados no formato PDF. Embora a proposta possa futuramente ser adaptada para outros formatos documentais, esta etapa concentra-se em materiais estruturados em páginas, como apostilas, capítulos de livros e apresentações convertidas para PDF. Portanto, não são contemplados, neste momento, formatos de texto fluido sem paginação nativa, como arquivos EPUB brutos, nem documentos baseados em hipertextos interativos externos.

1.1 Objetivos

1.1.1 *Objetivo Geral*

Desenvolver uma arquitetura de Geração Aumentada por Recuperação Multimodal (MRAG) voltada à consulta de materiais de estudo em PDF, combinando segmentação de layout e extração de elementos visuais estruturantes, com o objetivo de fornecer ao modelo gerador evidências mais específicas e contextualizadas, contribuindo para a redução de alucinações semânticas no contexto educacional.

1.1.2 *Objetivos Específicos*

- Projetar *pipelines* de processamento e indexação multimodal para identificar elementos textuais e visuais, como tabelas, gráficos e diagramas, vinculando-os de forma granular ao contexto documental correspondente;
- Desenvolver mecanismos de refinamento contextual para selecionar os componentes mais relevantes e reduzir ruídos visuais e textuais do material didático antes da etapa de geração da resposta;
- Desenvolver um protótipo da aplicação cliente LuminIA Reader, concebido como meio de interação com a arquitetura EDGAR, permitindo a submissão de documentos, o envio de perguntas e a visualização das respostas e evidências recuperadas;
- Avaliar a viabilidade técnica da arquitetura por meio de testes experimentais, utilizando métricas automatizadas e cenários baseados em materiais didáticos reais para analisar a qualidade da recuperação, a fidelidade das respostas e a latência computacional dos fluxos propostos.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos fundamentais e o panorama tecnológico que sustentam o desenvolvimento deste estudo. Inicialmente, a Seção 2.1 aborda os grandes modelos de linguagem (LLMs) e o impacto das alucinações semânticas no contexto educacional. Em seguida, a Seção 2.2 discute o funcionamento da arquitetura RAG tradicional e suas limitações diante de documentos com layouts complexos. Na sequência, a Seção 2.3 apresenta o paradigma multimodal (MRAG) e o uso de modelos de visão computacional aplicados à análise de documentos. Por fim, a Seção 2.4 analisa as técnicas de segmentação de layout e extração de componentes digitais, estabelecendo os critérios utilizados no processamento de arquivos PDF.

2.1 Grandes modelos de linguagem e alucinações no ensino

A compreensão, interpretação e geração da linguagem humana por computadores constituem alguns dos desafios mais antigos e centrais da Ciência da Computação, especialmente no campo do Processamento de Linguagem Natural (PLN) (Jurafsky e Martin, 2008). Nos últimos anos, essa área passou por avanços significativos com o surgimento dos Grandes Modelos de Linguagem, ou *Large Language Models* (LLMs), que formam a base tecnológica de muitos sistemas conversacionais e geradores de texto atuais (Zhao *et al.*, 2026). Esse avanço foi impulsionado pela arquitetura *Transformer*, introduzida por Vaswani *et al.* (2017), baseada no mecanismo de autoatenção (*self-attention*), que permite ao modelo considerar simultaneamente diferentes partes de um texto. Diferentemente de abordagens sequenciais tradicionais, essa característica favorece a identificação de relações contextuais entre termos, frases e trechos ao longo de um documento.

Por trás da aparente inteligência dessas ferramentas, o funcionamento básico de um LLM baseia-se em processos probabilísticos. Diante de uma pergunta ou comando, o modelo utiliza mecanismos de autoatenção não para consultar uma base de dados estática de informações verificadas, mas para analisar o contexto fornecido na entrada e estimar, token por token, qual é a continuação mais provável para aquela sequência (Tunstall *et al.*, 2022). Como esse processo se apoia em padrões estatísticos aprendidos durante o treinamento, o sistema tende a priorizar a construção de respostas que pareçam naturais e coerentes para quem lê, mesmo que o modelo não possua, por si só, um mecanismo nativo de verificação factual das informações geradas (Wolfram, 2023).

Essa natureza estatística contribui para uma limitação estrutural relevante dos LLMs, conhecida como alucinação semântica. Esse fenômeno ocorre quando a inteligência artificial gera respostas linguisticamente coerentes, mas que apresentam informações falsas, imprecisas ou não fundamentadas. Na literatura técnica, essas falhas costumam ser divididas em duas categorias: alucinações intrínsecas, quando o modelo contradiz ou ignora informações fornecidas pelo próprio usuário no comando; e alucinações extrínsecas, quando o sistema introduz fatos, nomes ou regras que não são sustentados pelas fontes disponíveis (Ji *et al.*, 2023). Esse comportamento pode estar relacionado a inconsistências e vieses presentes nos dados de treinamento, bem como à tendência dos modelos de produzir continuações textuais plausíveis mesmo quando não possuem evidências suficientes para sustentar a resposta (Alansari e Luqman, 2026).

No ambiente de ensino, essa vulnerabilidade técnica assume implicações pedagógicas relevantes, uma vez que o uso de LLMs como tutores individualizados pode estabelecer uma relação de confiança entre o estudante e a ferramenta (Kasneci *et al.*, 2023). Conforme alertam os autores, por estar em processo de aquisição e consolidação de conhecimento, o aluno nem sempre possui o repertório necessário para identificar alucinações sutis, especialmente quando elas aparecem em respostas formuladas com coerência, fluidez e aparente autoridade. Esse cenário, conforme corroborado por Holmes *et al.* (2023), pode induzir o estudante ao erro de maneira pouco perceptível, favorecendo a consolidação de equívocos conceituais e comprometendo a qualidade do processo de aprendizagem.

2.2 Geração aumentada por recuperação tradicional e suas limitações

Como forma de mitigar as alucinações semânticas e ampliar a base de conhecimento dos LLMs sem a necessidade de novos processos custosos de treinamento, a comunidade de inteligência artificial desenvolveu o conceito de Geração Aumentada por Recuperação (RAG) (Lewis *et al.*, 2020). Em sua abordagem tradicional, também conhecida como RAG linear ou ingênua (*Naive RAG*), esse paradigma é descrito por Gao *et al.* (2023) como a integração entre um mecanismo de busca e um modelo gerador. Nesse fluxo, os documentos didáticos em PDF são inicialmente convertidos em conteúdo textual e segmentados em blocos menores, por meio da técnica de *chunking*. Em seguida, esses fragmentos são transformados em vetores numéricos de alta dimensão, chamados de *embeddings*, que são indexados e armazenados em um banco de dados vetorial especializado.

A dinâmica de consulta desse ecossistema ocorre em tempo de execução, a partir

da interação do usuário. Nesse momento, a pergunta submetida é processada pelo mesmo modelo de conversão utilizado na etapa de indexação, gerando um vetor de busca. Conforme detalhado por Tunstall *et al.* (2022), o sistema executa uma busca vetorial no banco de dados por meio de cálculos de proximidade, como a similaridade de cosseno, identificando os blocos de texto cujo contexto apresenta maior alinhamento com a dúvida enviada. Em seguida, os fragmentos recuperados são inseridos no *prompt* de entrada do LLM, servindo como uma base de conhecimento complementar. Dessa forma, de acordo com o paradigma proposto por Lewis *et al.* (2020), o modelo gerador passa a construir a resposta com apoio em informações previamente recuperadas, em vez de depender apenas dos padrões aprendidos durante seu treinamento, o que contribui para reduzir a ocorrência de alucinações.

Apesar do bom desempenho dessa abordagem em textos corridos e lineares, o RAG tradicional apresenta limitações estruturais quando aplicado a documentos com layout complexo, como livros didáticos e materiais de estudo em formato PDF. Um dos principais desafios está na perda ou simplificação de elementos não textuais, uma vez que tabelas, gráficos, infográficos e diagramas explicativos nem sempre são adequadamente preservados por extratores de texto convencionais, limitando o acesso do LLM a informações visuais relevantes para o aprendizado (Faysse *et al.*, 2025). Além disso, a segmentação do documento em blocos de tamanho fixo pode comprometer a ordem lógica da informação. Em materiais educacionais, é comum que a explicação teórica esteja posicionada ao lado de uma imagem, associada a uma tabela ou distribuída em caixas de destaque. Entretanto, a leitura predominantemente linear do RAG tradicional tende a desconsiderar parte dessa hierarquia visual, podendo misturar fragmentos desconexos, gerar ruídos e comprometer a qualidade do contexto fornecido ao modelo de linguagem (Gao *et al.*, 2023).

2.3 Geração aumentada por recuperação multimodal e modelos de visão

Para superar parte das limitações do RAG tradicional na interpretação de layouts complexos, a área de inteligência artificial tem avançado em direção à Geração Aumentada por Recuperação Multimodal (MRAG) (Mei *et al.*, 2025). A principal contribuição desse paradigma está na capacidade de alinhar diferentes modalidades de dados, como texto e imagem, em um mesmo espaço vetorial. Sob essa perspectiva, o sistema passa a tratar o material didático não apenas como uma sequência linear de texto, mas também a partir de suas representações visuais e estruturais. Isso permite correlacionar semanticamente uma dúvida textual submetida por um

estudante a elementos visuais correspondentes, como gráficos, tabelas ou diagramas, ampliando a relevância desses componentes no processo de recuperação da informação (Mei *et al.*, 2025).

Essa abordagem foi viabilizada pelo avanço dos modelos de linguagem e visão (*Vision-Language Models* – VLMs), os quais, conforme discutido na literatura recente (Yin *et al.*, 2024), podem reduzir a dependência de intermediários tradicionais, como os sistemas de reconhecimento óptico de caracteres (OCR), ao processarem diretamente as representações visuais das páginas dos documentos. Nesse contexto, a arquitetura *ColPali*, introduzida por Faysse *et al.* (2025), representa um avanço relevante ao aplicar o conceito de interação tardia (*Late Interaction*) à busca documental. Segundo os autores, em vez de compactar uma página inteira em um único vetor, essa estratégia gera múltiplos *embeddings* associados a diferentes regiões da imagem, permitindo que o mecanismo considere detalhes visuais e textuais de forma mais granular. Com isso, torna-se possível preservar melhor informações presentes em tabelas complexas, fórmulas matemáticas e infográficos, favorecendo uma recuperação documental com maior fidelidade semântica.

Apesar dos avanços no mapeamento visual de documentos, as implementações atuais de MRAG ainda apresentam desafios técnicos relacionados ao ruído contextual. Em sistemas baseados no *ColPali*, é comum que a captura da página inteira seja recuperada e enviada como contexto para o LLM gerar a resposta. Com isso, o modelo gerador pode receber informações pouco relevantes presentes na mesma página, como cabeçalhos, rodapés, números de página e parágrafos associados a assuntos adjacentes (Yun *et al.*, 2025). Esse excesso de dados visuais pode ocupar parte da janela de contexto da inteligência artificial e reduzir a precisão do processo de geração, ampliando a possibilidade de ocorrência de alucinações semânticas (Liu *et al.*, 2025). Portanto, torna-se necessário desenvolver estratégias de engenharia voltadas ao isolamento granular dos componentes visuais relevantes, de modo a refinar o contexto antes da etapa de geração.

2.4 Segmentação de layout e processamento de documentos

Para enfrentar o problema do ruído contextual gerado pela captura de páginas inteiras, a engenharia de software e a visão computacional recorrem às técnicas de análise de layout de documentos (*Document Layout Analysis* – DLA). Essa subárea investiga métodos capazes de identificar a estrutura geométrica e a organização lógica de um arquivo digital (Zhong *et al.*, 2019). Em vez de tratar o documento PDF apenas como uma sequência linear de caracteres

ou como uma imagem única e indivisível, os modelos de DLA analisam a página para detectar e delimitar seus componentes estruturais por meio de caixas delimitadoras, conhecidas como *bounding boxes*. Esse mapeamento automático permite estimar as coordenadas bidimensionais de cada bloco de informação, segmentando o arquivo em componentes lógicos, como títulos, parágrafos, tabelas, figuras e listas (Zhong *et al.*, 2019).

O avanço na precisão dessa segmentação foi impulsionado pelo surgimento de modelos de aprendizado profundo voltados à compreensão conjunta de texto, imagem e layout, como a família *LayoutLM*. A arquitetura proposta por Xu *et al.* (2020) demonstrou a importância de processar o conteúdo textual em associação direta com sua posição espacial na página, superando limitações de abordagens que analisavam texto e estrutura visual de forma separada. Esse paradigma foi ampliado no *LayoutLMv3*, apresentado por Huang *et al.* (2022), por meio da unificação do aprendizado multimodal a partir de objetivos de pré-treinamento que consideram simultaneamente texto, imagem e geometria do layout. Como resultado, esse tipo de modelagem favorece a classificação dos blocos detectados e oferece suporte técnico para que sistemas de processamento documental diferenciem elementos estruturais secundários, como cabeçalhos e rodapés, de componentes com maior relevância informacional e pedagógica, como tabelas, gráficos e caixas de texto explicativas.

Uma vez identificadas e classificadas as coordenadas estruturais do documento, torna-se possível aplicar um processamento voltado à filtragem granular dos dados. A partir da localização do elemento relevante, estimada pelos modelos de DLA, viabiliza-se a execução de operações de recorte digital (*cropping*) para isolar o bloco de interesse e reduzir ruídos visuais periféricos, especialmente em documentos com layouts complexos (Zhong *et al.*, 2019). Esse processo de refino e curadoria contribui para diminuir a inserção de informações pouco relevantes na janela de contexto do modelo gerador, uma etapa importante, visto que o excesso de ruído textual e visual pode prejudicar a capacidade de raciocínio e a acurácia dos modelos de linguagem (Liu *et al.*, 2024; Liu *et al.*, 2025). Desse modo, a literatura indica que a integração entre análise visual avançada e segmentação estrutural pode favorecer a fidelidade da recuperação e contribuir para a mitigação de alucinações conceituais em sistemas de busca documental (Gao *et al.*, 2023).

3 TRABALHOS RELACIONADOS

Neste capítulo, são apresentadas pesquisas recentes que abordam o problema da recuperação multimodal em documentos complexos, destacando seus pontos de convergência com a presente proposta, bem como as limitações que motivam o desenvolvimento do EDGAR.

3.1 ColPali: Efficient Document Retrieval with Vision Language Models

Faysse *et al.* (2025) propõem o *ColPali*, uma arquitetura de recuperação de documentos que substitui os tradicionais *pipelines* de extração textual por um modelo de linguagem e visão (VLM) capaz de indexar páginas inteiras como representações visuais. O sistema opera por meio de um mecanismo de interação tardia (*late interaction*), que compara vetores associados a *patches* visuais da página com a consulta do usuário. Com isso, a abordagem reduz a dependência de OCR e simplifica o fluxo de indexação de documentos complexos. Os resultados apresentados pelos autores indicam desempenho competitivo em *benchmarks* de recuperação documental com *layouts* complexos, incluindo tabelas, fórmulas e infográficos.

Essa mudança de perspectiva é especialmente relevante para a presente proposta, pois desloca a recuperação documental de uma leitura estritamente textual para uma leitura sensível à organização visual da página. Nesse sentido, o *ColPali* aproxima-se do EDGAR ao tratar o PDF como uma estrutura visual relevante para a recuperação da informação, e não apenas como uma sequência linear de texto extraído. Em ambos os casos, elementos como tabelas, gráficos, fórmulas e diagramas são compreendidos como partes importantes do conteúdo, capazes de concentrar informações essenciais para responder a uma consulta. Assim, os dois trabalhos convergem ao reconhecer que a disposição visual dos elementos no documento influencia diretamente a qualidade da recuperação.

Apesar dessa aproximação, a diferença central entre as abordagens está na unidade de recuperação adotada. Enquanto o *ColPali* indexa e recupera páginas inteiras por meio de representações visuais, o EDGAR propõe uma recuperação em granularidade fina, baseada na segmentação prévia da página em componentes documentais. Na arquitetura proposta, os modelos de visão são utilizados de forma complementar ao *pipeline*: a análise de layout delimita os componentes da página e a descrição visual transforma recortes específicos em representações textuais indexáveis. Dessa forma, busca-se recuperar evidências localizadas e rastreáveis, em vez de utilizar a página completa como principal unidade de contexto.

3.2 LILaC: Late Interacting in Layered Component Graph for Open-domain Multimodal Multihop Retrieval

Yun *et al.* (2025) apresentam o LILaC, um *framework* de recuperação multimodal que estrutura documentos como grafos de componentes em camadas, interligando explicitamente parágrafos, tabelas e imagens por meio de arestas semânticas e estruturais. Essa representação em grafo permite que o sistema realize consultas que exigem o cruzamento de informações distribuídas em múltiplas páginas, alcançando alta precisão em tarefas de recuperação multimodal multi-salto (*multihop*) em domínio aberto.

A contribuição do LILaC dialoga com este trabalho ao evidenciar que documentos complexos podem ser melhor explorados quando sua estrutura interna é considerada no processo de recuperação. Em vez de tratar o documento apenas como uma página inteira ou como blocos textuais fixos, o *framework* organiza o conteúdo em componentes menores, como parágrafos, tabelas, imagens e figuras. Essa perspectiva aproxima-se da proposta do EDGAR, pois ambos consideram que a interpretação de documentos multimodais depende da relação entre elementos textuais e visuais, especialmente quando a resposta a uma consulta exige recuperar informações distribuídas em diferentes partes do material.

Entretanto, o modo como cada abordagem representa essas relações segue caminhos distintos. No LILaC, a conexão entre os componentes é modelada por meio de grafos em camadas e mecanismos de recuperação multi-salto em domínio aberto. Já o EDGAR adota uma estratégia mais direta, baseada na associação entre cada componente isolado, seus textos extraídos, descrições visuais e metadados geométricos. Assim, em vez de construir uma estrutura de grafo para apoiar o raciocínio entre múltiplos componentes, a arquitetura proposta organiza as evidências em unidades recuperáveis de granularidade fina, priorizando a rastreabilidade visual e a redução de complexidade no fluxo de consulta. Dessa forma, o EDGAR diferencia-se do LILaC ao privilegiar uma representação mais leve e voltada ao domínio educacional, na qual a recuperação de componentes específicos do material didático é tratada como elemento central da arquitetura.

3.3 SLEUTH: Resolving Evidence Sparsity via Agentic Context Engineering for Long-Document Understanding

Liu *et al.* (2025) propõem o SLEUTH, um *framework* baseado em engenharia de contexto agêntica para a compreensão de documentos longos. O sistema emprega múltiplos agentes de inteligência artificial colaborativos que refinam iterativamente a busca por evidências esparsas ao longo do documento, avaliando a complexidade das consultas, extraindo pistas textuais e visuais e consolidando os fragmentos recuperados em um contexto coerente para o modelo gerador. Essa abordagem demonstrou resultados expressivos em tarefas de compreensão que exigem raciocínio sobre evidências distribuídas em documentos extensos.

O ponto de contato com a presente proposta está na importância atribuída à engenharia de contexto. Assim como o SLEUTH, o EDGAR parte da compreensão de que a qualidade da resposta gerada depende não apenas da quantidade de informação recuperada, mas também da forma como essas evidências são selecionadas, organizadas e fornecidas ao modelo de linguagem. Em documentos extensos ou visualmente complexos, essa etapa torna-se especialmente relevante, pois a inserção indiscriminada de grandes volumes de conteúdo pode introduzir informações periféricas e comprometer a fidelidade da resposta.

A distinção entre as abordagens aparece, sobretudo, na temporalidade dessa curadoria. No SLEUTH, o refinamento das evidências ocorre dinamicamente durante a consulta, por meio de múltiplos agentes responsáveis por buscar, avaliar e consolidar fragmentos relevantes. Já no EDGAR, parte desse esforço é deslocada para o fluxo assíncrono de ingestão e indexação, no qual a análise de layout, o isolamento geométrico, a extração textual localizada e a descrição visual de componentes são utilizados para preparar previamente unidades de evidência mais específicas e rastreáveis. Com isso, a arquitetura proposta evita depender de uma curadoria agêntica iterativa no momento da consulta, priorizando uma organização estrutural prévia do documento para reduzir o custo computacional do fluxo síncrono.

3.4 Análise Comparativa

A Tabela 1 sintetiza os principais eixos de diferenciação entre os trabalhos relacionados e a arquitetura proposta neste estudo. Os critérios de comparação foram selecionados com base nas dimensões mais relevantes para o domínio educacional: a precisão da recuperação, o custo computacional associado e a capacidade de lidar com a estrutura multimodal e pedagógica

dos materiais didáticos em PDF.

Tabela 1 – Análise comparativa dos trabalhos relacionados e o presente trabalho.

Critério	ColPali	LILaC	SLEUTH	EDGAR
Granularidade de recuperação	Página inteira	Componente via grafo	Trecho por agente	Componente documental
Custo computacional	Baixo	Alto	Alto	Moderado
Suporte a elementos visuais	Sim	Sim	Sim	Sim
Preserva relações entre componentes	Não	Sim	Parcial	Sim
Orquestração de múltiplos agentes	Não	Não	Sim	Não
Mitigação proativa de alucinações	Não	Não	Sim (Síncrona)	Sim (Assíncrona)
Foco em domínio educacional	Não	Não	Não	Sim
Requer OCR	Não	Sim	Não	Seletivo

Fonte: Elaborado pelo autor.

A análise evidencia que, embora os trabalhos relacionados apresentem contribuições relevantes para a recuperação multimodal, eles não conciliam simultaneamente granularidade fina de recuperação, rastreabilidade das evidências e sensibilidade à estrutura pedagógica dos documentos. O *ColPali*, apesar de sua eficiência, opera em granularidade de página inteira, o que pode introduzir ruído visual no contexto fornecido ao modelo. O *LILaC* e o *SLEUTH* alcançam maior precisão em seus respectivos cenários de avaliação, porém dependem de estratégias computacionalmente mais intensivas, como grafos em camadas ou múltiplos agentes, cuja latência acumulada pode comprometer a interatividade em tempo de consulta. O *EDGAR* propõe-se a ocupar essa lacuna ao combinar recuperação em nível de componente documental, preparação assíncrona das evidências e preservação de metadados geométricos, características orientadas à consulta de materiais didáticos multimodais em PDF.

4 METODOLOGIA

Este capítulo apresenta a abordagem metodológica adotada para a concepção, estruturação e avaliação da arquitetura EDGAR. Inicialmente, são descritas as premissas arquiteturais que orientam a proposta, incluindo a separação entre as etapas de preparação documental e de atendimento às consultas do usuário. Em seguida, são definidos os componentes tecnológicos utilizados na implementação, bem como os fluxos de processamento responsáveis pela ingestão, indexação, recuperação e organização das evidências extraídas de documentos didáticos em PDF. Por fim, apresenta-se o planejamento experimental elaborado para avaliar a viabilidade técnica da arquitetura e sua integração com a aplicação cliente LuminIA Reader.

4.1 Visão geral da arquitetura EDGAR

A arquitetura proposta neste trabalho foi concebida como uma abordagem de Geração Aumentada por Recuperação Multimodal em granularidade fina, voltada ao processamento e à consulta de documentos didáticos em PDF. Do ponto de vista metodológico, sua construção será organizada como um *pipeline* de engenharia de dados e contexto, sem necessidade de treinamento adicional (*training-free*) ou ajuste fino (*fine-tuning*) dos modelos utilizados. Assim, a proposta concentra-se na articulação de componentes previamente disponíveis, como modelos de análise de layout, mecanismos de extração textual, modelos de descrição visual, técnicas de vetorização e modelos de linguagem geradores.


Para viabilizar a interação do usuário com o sistema, será utilizado o LuminIA Reader como aplicação cliente de apoio. No escopo deste trabalho, essa aplicação não constitui o objeto principal da pesquisa, mas atua como meio de submissão dos documentos, envio das perguntas e visualização das respostas e evidências retornadas pela arquitetura. Dessa forma, o LuminIA Reader funciona como uma camada de demonstração e validação prática da proposta, enquanto o foco metodológico permanece nos módulos de ingestão, indexação, recuperação e geração.

De maneira geral, o fluxo de uso inicia-se com o envio de um documento didático em PDF por meio da aplicação cliente. Esse documento é encaminhado à camada de processamento da arquitetura, responsável por realizar a segmentação, o enriquecimento semântico e a indexação dos componentes documentais. Posteriormente, quando o usuário submete uma pergunta, o sistema recupera os componentes mais relevantes, organiza as evidências em um contexto de

entrada para o modelo gerador e retorna uma resposta acompanhada dos metadados necessários para a visualização da evidência no documento original.

Internamente, a arquitetura será organizada em dois fluxos principais. O primeiro corresponde ao fluxo assíncrono de ingestão e indexação, responsável por preparar previamente o documento, convertendo páginas em imagens, identificando regiões estruturais, recortando componentes, extraindo texto, gerando descrições visuais e armazenando representações vetoriais com metadados geométricos. O segundo corresponde ao fluxo síncrono de recuperação e geração, acionado no momento da consulta do usuário, no qual a pergunta é vetorizada, as evidências são recuperadas, o contexto é estruturado e a resposta é produzida pelo modelo gerador. A Figura 1 sintetiza esse funcionamento, apresentando de forma integrada tanto o fluxo geral de uso da arquitetura quanto a organização interna de seus módulos assíncronos e síncronos.

Figura 1 – Visão geral do funcionamento da arquitetura EDGAR.



Fonte: Elaborado pelo autor.

Essa separação entre preparação documental e atendimento à consulta busca concentrar as etapas mais custosas no fluxo assíncrono, reduzindo o processamento necessário

durante a interação do estudante. A partir dessa organização, as seções seguintes apresentam os componentes tecnológicos definidos para a arquitetura e detalham as fases que compõem seus fluxos assíncrono e síncrono.

4.2 Definição dos componentes tecnológicos

A partir da organização arquitetural apresentada na Figura 1, foram definidos os principais componentes tecnológicos utilizados na arquitetura EDGAR e em sua comunicação com a aplicação cliente LuminIA Reader. A seleção dessas tecnologias considerou critérios como disponibilidade em código aberto, compatibilidade com execução em ambiente de nuvem, integração com aplicações web e adequação ao processamento de documentos didáticos em PDF. A Tabela 2 sintetiza os módulos que compõem a base tecnológica da proposta.

Tabela 2 – Componentes tecnológicos definidos para a arquitetura do presente trabalho e sua camada de aplicação cliente.

Módulo	Tecnologia definida	Função na arquitetura
Conversão de PDF para imagem	PyMuPDF	Renderizar páginas PDF como imagens padronizadas para análise visual.
Análise de layout de documentos	DocLayout-YOLO	Detectar regiões estruturais da página e gerar <i>bounding boxes</i> .
Isolamento geométrico	OpenCV	Recortar componentes visuais a partir das coordenadas detectadas.
Extração textual localizada	PyMuPDF / Tesseract OCR	Extrair texto de componentes digitais ou escaneados.
Descrição visual de componentes	Qwen2.5-VL-7B-Instruct	Gerar descrições textuais estruturadas de elementos visuais recortados.
Vetorização textual	BGE-M3 via Sentence Transformers	Gerar vetores semânticos dos textos extraídos e descrições visuais.
Banco de dados vetorial	Qdrant	Armazenar <i>embeddings</i> e metadados dos componentes documentais.
Modelo de linguagem gerador	Qwen2.5-7B-Instruct	Gerar respostas a partir das evidências recuperadas.
Interface web	Vue.js / PDF.js	Implementar a aplicação cliente LuminIA Reader.

Fonte: Elaborado pelo autor.

4.2.1 Justificativa das tecnologias adotadas

A escolha dos componentes apresentados na Tabela 2 foi orientada pela aderência de cada recurso às necessidades específicas da arquitetura EDGAR e à sua integração com a aplicação cliente LuminIA Reader. A seguir, são apresentadas as justificativas técnicas para os módulos adotados.

- **Conversão de PDF para imagem:** A escolha do PyMuPDF justifica-se por sua capacidade de converter páginas PDF em imagens rasterizadas com controle de resolução, além de permitir o acesso programático à estrutura interna do documento. Essa característica é relevante para o EDGAR, pois a etapa de normalização visual precisa preservar a correspondência entre o arquivo original, o número da página, a imagem gerada e as coordenadas utilizadas nas fases posteriores de análise de layout e isolamento de componentes. A resolução inicial de 300 DPI foi adotada como ponto de equilíbrio entre fidelidade visual e custo computacional, podendo ser ajustada conforme os resultados observados nas etapas de detecção de layout e OCR seletivo. Além disso, o uso do PyMuPDF favorece a integração entre conversão visual e extração textual em documentos digitais, reduzindo a necessidade de dependências externas adicionais no primeiro estágio do *pipeline*.
- **Análise de layout de documentos:** A escolha do DocLayout-YOLO justifica-se por sua especialização na detecção visual de estruturas documentais e por sua adequação a cenários que exigem equilíbrio entre precisão e desempenho computacional. No presente trabalho, esse módulo é responsável por identificar os elementos estruturais da página e gerar *bounding boxes* associadas a rótulos de classe e índices de confiança. Esses dados constituem a base geométrica para o isolamento dos blocos detectados, a extração textual localizada e a posterior associação entre evidências visuais, conteúdo textual e metadados de recuperação. Além disso, por operar sobre a imagem renderizada da página, o modelo mantém compatibilidade tanto com PDFs digitais quanto com documentos escaneados, preservando a premissa de normalização visual adotada no fluxo de ingestão.
- **Isolamento geométrico:** A escolha do OpenCV justifica-se por sua maturidade como biblioteca de visão computacional e por sua integração direta com estruturas matriciais de imagem em Python. No EDGAR, esse módulo utiliza as coordenadas das *bounding boxes* geradas pela análise de layout para recortar regiões de interesse da página renderizada, produzindo componentes isolados. Esses artefatos intermediários são essenciais para a extração textual localizada, para a associação entre evidências visuais e metadados

geométricos e para a posterior renderização das regiões recuperadas na interface LuminIA Reader. Além disso, o OpenCV oferece recursos adicionais de pré-processamento, como redimensionamento, conversão de espaço de cor e filtragem, que podem auxiliar na preparação dos componentes para OCR e validação visual.

- **Extração textual localizada:** A escolha combinada do PyMuPDF e do Tesseract OCR justifica-se pela necessidade de tratar documentos PDF com diferentes características de origem. Em PDFs digitais, o PyMuPDF permite acessar diretamente a camada textual do documento e recuperar palavras ou blocos associados a posições específicas da página, possibilitando a extração apenas do conteúdo contido nas coordenadas do componente detectado. Em documentos escaneados ou em regiões sem texto digital acessível, o Tesseract OCR será aplicado de forma seletiva sobre o recorte visual previamente isolado. Essa estratégia híbrida evita a aplicação indiscriminada de OCR sobre páginas inteiras, reduz o custo computacional e contribui para preservar a correspondência entre componente visual, conteúdo textual e metadados geométricos.
- **Descrição visual de componentes:** A escolha do Qwen2.5-VL-7B-Instruct justifica-se pela necessidade de representar semanticamente elementos visuais cujo conteúdo não pode ser plenamente capturado apenas por extração textual ou OCR. Em materiais didáticos, gráficos, diagramas, figuras, esquemas e algumas tabelas podem transmitir informações relevantes por meio de relações espaciais, formas, setas, agrupamentos e organização visual. No EDGAR, esse modelo será aplicado no fluxo assíncrono sobre os recortes previamente isolados, gerando descrições textuais estruturadas desses elementos. Essas descrições complementam o texto extraído do documento e são posteriormente vetorizadas e indexadas no banco vetorial. Dessa forma, o modelo gerador utilizado no fluxo síncrono pode responder às consultas do estudante com apoio em uma representação textual enriquecida dos elementos visuais, sem a necessidade de processar imagens diretamente no momento da consulta.
- **Banco de dados vetorial:** A escolha do Qdrant justifica-se por sua adequação a cenários de recuperação semântica que dependem da associação entre vetores e metadados estruturados. No EDGAR, cada componente extraído do documento precisa ser armazenado juntamente com informações como identificador do arquivo, número da página, classe do elemento, coordenadas geométricas e referência ao recorte visual correspondente. O suporte a *payloads* e filtros permite combinar a busca vetorial com critérios estruturais, favorecendo

a recuperação das evidências necessárias tanto para a geração da resposta quanto para a renderização visual posterior na interface LuminIA Reader. Além disso, a possibilidade de execução em ambiente de servidor contribui para a integração do Qdrant ao arranjo cliente-servidor proposto.

- **Vetorização textual:** A escolha do BGE-M3, utilizado por meio da biblioteca Sentence Transformers, justifica-se por sua adequação a tarefas de recuperação semântica multilíngue e por sua compatibilidade com entradas textuais em diferentes níveis de granularidade. No EDGAR, os textos submetidos à vetorização incluem tanto o conteúdo extraído dos componentes por meio do PyMuPDF ou do OCR quanto as descrições visuais geradas para figuras, gráficos, diagramas e demais elementos não textuais. Dessa forma, o uso de um modelo de *embeddings* multilíngue favorece a representação semântica integrada desses fragmentos e permite comparar a pergunta do estudante com os componentes indexados no banco vetorial. A biblioteca Sentence Transformers, por sua vez, oferece uma interface programática consolidada para a geração de *embeddings* e a integração com mecanismos de busca semântica.
- **Interface web:** A escolha do Vue.js e do PDF.js justifica-se pela necessidade de construir uma aplicação cliente interativa, capaz de mediar a comunicação entre o estudante e a arquitetura EDGAR. O Vue.js permite organizar a interface do LuminIA Reader em componentes reativos, como visualizador do documento, painel de perguntas, área de respostas e camada de destaque das evidências. O PDF.js, por sua vez, viabiliza a renderização de documentos PDF diretamente no navegador, permitindo controlar a página exibida, a escala de visualização e a sobreposição de elementos gráficos. Essa combinação favorece a implementação do mecanismo de visualização de evidências, no qual as coordenadas geométricas retornadas pela arquitetura são utilizadas para destacar visualmente o componente recuperado no material didático.

A definição desses componentes permite delimitar uma base tecnológica coerente com os requisitos da arquitetura proposta, mantendo alinhamento com a premissa de uso de ferramentas abertas e com a separação entre processamento documental, recuperação semântica e interação com o usuário. Embora ajustes pontuais possam ocorrer durante a implementação, a organização apresentada estabelece os módulos necessários para viabilizar o fluxo de dados em granularidade fina no EDGAR, bem como sua comunicação com a interface LuminIA Reader para leitura, consulta, visualização de evidências e validação prática do sistema.

4.3 Fluxo assíncrono de ingestão e indexação

O fluxo assíncrono de ingestão e indexação, também referido como fluxo *offline*, corresponde à etapa responsável por transformar documentos didáticos em PDF em uma base de conhecimento estruturada, composta por fragmentos textuais, recortes visuais e metadados geométricos. Esse processamento é executado em segundo plano após o envio do arquivo pela aplicação cliente LuminIA Reader, permitindo que as etapas de maior custo computacional sejam realizadas antes das consultas do usuário. Dessa forma, o fluxo síncrono de recuperação e geração pode concentrar-se na busca das evidências previamente indexadas e na elaboração da resposta. O fluxo assíncrono é composto por seis fases consecutivas e interdependentes, descritas nas subseções seguintes.

4.3.1 Fase 1: Unificação visual e normalização de entrada

A etapa inicial do *pipeline* dedica-se à padronização da entrada documental. Materiais didáticos em PDF podem apresentar diferentes características de origem, incluindo arquivos digitais com camada textual selecionável e documentos escaneados compostos apenas por imagens. Para reduzir essa heterogeneidade e permitir que os módulos seguintes operem sobre uma representação visual comum, o EDGAR utiliza o PyMuPDF para converter cada página do PDF em uma imagem rasterizada.

A conversão será realizada inicialmente em 300 DPI, valor adotado como ponto de equilíbrio entre fidelidade visual e custo computacional, podendo ser ajustado conforme os resultados observados nas etapas de análise de layout e extração textual localizada. Como saída desta fase, cada página passa a possuir uma imagem correspondente, associada ao identificador do documento, ao número da página e às dimensões utilizadas como referência para as coordenadas geométricas empregadas nas etapas seguintes.

4.3.2 Fase 2: Análise de layout de documentos (DLA)

Com as páginas convertidas em imagens padronizadas, o EDGAR aciona o módulo de Análise de Layout de Documentos, do inglês *Document Layout Analysis* (DLA). Essa etapa utiliza o DocLayout-YOLO para detectar, classificar e delimitar regiões estruturais presentes na página, como blocos textuais, tabelas, figuras, legendas, fórmulas matemáticas e caixas de destaque.

A entrada corresponde à imagem renderizada da página, enquanto a saída consiste em um conjunto de elementos detectados, cada um associado a uma classe, a um índice de confiança e a uma *bounding box*. Essas caixas são representadas por coordenadas que indicam seus limites nos eixos X e Y. Esse mapeamento espacial constitui a base para a recuperação em granularidade fina, pois permite que o documento deixe de ser tratado como uma página indivisível e passe a ser organizado em componentes estruturais independentes.

4.3.3 Fase 3: Isolamento geométrico de componentes (*cropping*)

A terceira fase realiza o isolamento geométrico dos componentes identificados pela análise de layout. A partir das *bounding boxes* geradas na etapa anterior, o EDGAR utiliza o OpenCV para recortar regiões de interesse diretamente sobre a imagem renderizada da página. Esse procedimento produz imagens menores, correspondentes aos elementos detectados, como tabelas, figuras, trechos textuais ou caixas explicativas.

O objetivo desta fase é reduzir a presença de ruídos visuais e textuais adjacentes, como cabeçalhos, rodapés, números de página ou conteúdos paralelos que compartilham a mesma folha. Como resultado, cada região isolada passa a constituir uma unidade documental indexável, preservando sua relação com o documento de origem, o número da página e as coordenadas utilizadas para sua localização. Esses recortes também poderão ser empregados posteriormente tanto na extração textual localizada quanto na visualização das evidências na interface LuminIA Reader.

4.3.4 Fase 4: Extração textual localizada (*OCR seletivo*)

Após o isolamento dos componentes, o *pipeline* realiza a extração textual de forma localizada. Essa fase adota uma estratégia híbrida, combinando PyMuPDF e Tesseract OCR conforme a natureza do arquivo processado. Em PDFs digitais com camada textual acessível, o PyMuPDF é utilizado para recuperar palavras ou blocos associados às coordenadas do componente detectado, evitando a aplicação desnecessária de OCR.

Nos casos em que o material é escaneado, ou quando não há texto digital confiável na região analisada, o Tesseract OCR é aplicado seletivamente sobre o recorte visual previamente isolado. Essa abordagem evita o processamento indiscriminado de páginas inteiras e reduz problemas comuns em documentos com layout complexo, como quebras incorretas de leitura, desalinhamento de tabelas e mistura de conteúdos pertencentes a regiões distintas da página.

Como saída, cada componente passa a possuir, além de sua representação visual e geométrica, um conteúdo textual associado.

4.3.5 Fase 5: Descrição visual de componentes

Após a extração textual localizada, o fluxo assíncrono realiza o enriquecimento semântico dos componentes visuais detectados no documento. Essa etapa tem como objetivo representar, em formato textual, informações presentes em elementos cuja compreensão não depende apenas de caracteres extraídos por OCR ou pela camada textual do PDF. Em materiais didáticos, componentes como gráficos, diagramas, figuras, esquemas, fórmulas e determinadas tabelas podem transmitir conhecimento por meio de relações espaciais, setas, agrupamentos, formas, proporções e organização visual.

Para lidar com esses casos, o presente trabalho utiliza o modelo Qwen2.5-VL-7B-Instruct sobre os recortes visuais previamente isolados. O modelo é aplicado de forma seletiva, priorizando componentes classificados como elementos visuais ou multimodais pela etapa de análise de layout. A partir de cada recorte, o sistema gera uma descrição textual estruturada contendo informações como o tipo do componente, os elementos visuais identificáveis, as relações relevantes entre esses elementos e uma síntese do conteúdo representado.

Essa descrição visual não substitui o recorte original nem a extração textual realizada na fase anterior. Em vez disso, atua como uma camada complementar de representação semântica, permitindo que informações originalmente visuais sejam posteriormente vetorizadas e recuperadas por meio de busca semântica. Dessa forma, diagramas, gráficos e figuras passam a integrar a base de conhecimento do EDGAR não apenas como imagens associadas a coordenadas, mas também como descrições textuais indexáveis.

Como saída desta fase, cada componente visual processado passa a possuir, além do recorte, da classe, das coordenadas e do texto extraído, quando disponível, uma descrição textual estruturada. Esse conteúdo será utilizado na etapa seguinte de vetorização e indexação, permitindo que o modelo gerador empregado no fluxo síncrono receba evidências enriquecidas sem a necessidade de processar imagens diretamente durante a consulta do estudante.

4.3.6 Fase 6: Vetorização e indexação multimodal híbrida

A fase final do fluxo *offline* consolida os componentes processados e os prepara para recuperação no momento da consulta. Nesta etapa, são reunidas as representações textuais

produzidas nas fases anteriores, incluindo o texto extraído diretamente do PDF ou por OCR localizado, bem como as descrições visuais estruturadas geradas para elementos como figuras, gráficos, diagramas, fórmulas e tabelas. Esses conteúdos são submetidos ao modelo BGE-M3, por meio da biblioteca Sentence Transformers, para a geração de vetores semânticos capazes de representar os componentes em um espaço vetorial multilíngue.

Em seguida, os vetores gerados são armazenados no Qdrant juntamente com seus metadados estruturais, incluindo identificador do documento, número da página, classe do componente, coordenadas geométricas, texto extraído, descrição visual e referência ao recorte correspondente. Essa organização permite que a busca semântica recupere não apenas fragmentos textuais relevantes, mas também elementos visuais previamente descritos e associados à sua posição original no documento.

Dessa forma, a indexação assume caráter multimodal híbrido, articulando texto extraído, descrição visual, recorte do componente e metadados geométricos em uma mesma unidade de recuperação. Essa estrutura permite que, no fluxo síncrono, o modelo gerador receba evidências enriquecidas sobre o conteúdo didático, enquanto a interface LuminIA Reader mantém a capacidade de exibir visualmente o componente original utilizado como base para a resposta.

4.4 Fluxo síncrono de recuperação e geração

O fluxo síncrono de recuperação e geração, também referido como fluxo *online*, corresponde à etapa responsável por atender às consultas realizadas pelo estudante na aplicação cliente LuminIA Reader. Diferentemente do fluxo assíncrono, no qual o documento é previamente segmentado, enriquecido semanticamente e indexado, esta etapa opera sobre a base de conhecimento já estruturada pelo EDGAR. Seu objetivo é recuperar evidências relevantes a partir da pergunta do usuário, organizar essas informações em um contexto adequado ao modelo gerador e retornar uma resposta acompanhada dos metadados necessários para rastrear sua origem no documento.

A separação entre os fluxos assíncrono e síncrono busca reduzir o custo computacional no momento da consulta, uma vez que as operações mais custosas de processamento documental, análise visual e descrição de componentes já foram executadas durante a ingestão. Assim, a etapa síncrona concentra-se em três operações principais: vetorização da pergunta, recuperação dos componentes mais relevantes no banco vetorial e geração da resposta com base

nas evidências recuperadas. Esse processo é composto por duas fases principais, seguidas pela comunicação com a interface cliente para visualização das evidências visuais associadas.

4.4.1 Fase 7: Recuperação semântica e associação de evidências

O fluxo inicia-se quando o estudante submete uma dúvida em linguagem natural por meio da aplicação cliente LuminIA Reader. A pergunta é encaminhada para o EDGAR, onde é convertida em uma representação semântica utilizando o mesmo modelo de *embeddings* adotado na etapa de indexação, o BGE-M3 via Sentence Transformers. Essa correspondência mantém a compatibilidade entre a representação da consulta e os vetores previamente armazenados para os componentes documentais.

Em seguida, a arquitetura realiza uma busca por similaridade no Qdrant, com o objetivo de identificar os componentes mais aderentes à intenção da consulta. A recuperação não se limita ao texto associado ao vetor encontrado. Cada resultado retornado pelo banco vetorial inclui também os metadados estruturais armazenados no fluxo assíncrono, como identificador do documento, número da página, classe do componente, coordenadas, texto extraído, descrição visual gerada e referência ao recorte correspondente.

Dessa forma, esta fase permite reconstruir a evidência em suas dimensões textual, visual e espacial. O texto extraído e a descrição visual estruturada são utilizados como base semântica para a geração da resposta, enquanto as coordenadas e o recorte preservam a rastreabilidade da informação no documento original. Esse mecanismo diferencia a arquitetura de abordagens baseadas apenas em fragmentos textuais, pois mantém a relação entre o conteúdo recuperado, sua representação visual e sua posição no material didático.

4.4.2 Fase 8: Engenharia de contexto e inferência

Após a recuperação dos componentes mais relevantes, o EDGAR organiza as evidências em um contexto de entrada para o modelo gerador. Essa etapa tem como finalidade selecionar e estruturar as informações recuperadas de modo que o modelo receba apenas os fragmentos diretamente relacionados à dúvida do estudante, evitando o envio de páginas completas ou blocos extensos com informações periféricas.

O contexto é composto pelos textos extraídos dos componentes, pelas descrições visuais geradas no fluxo assíncrono e por metadados mínimos de rastreabilidade, como página, classe do elemento e indicação da evidência visual associada. Os recortes visuais não são

utilizados como entrada direta do modelo nesta fase; eles permanecem vinculados ao componente recuperado para fins de verificação, rastreabilidade e visualização posterior na interface. Assim, o gerador textual atua sobre uma representação semântica previamente enriquecida dos elementos textuais e visuais do documento.

A resposta é então gerada pelo Qwen2.5-7B-Instruct, modelo de linguagem compacto da classe 7B–8B, selecionado por sua adequação a tarefas de resposta a perguntas, seguimento de instruções e suporte multilíngue. No contexto do EDGAR, o modelo não deve depender exclusivamente de seu conhecimento paramétrico, mas produzir uma resposta orientada pelas evidências recuperadas. Essa estratégia busca favorecer respostas mais aderentes ao material didático e reduzir a influência de ruídos marginais presentes no layout original do documento.


4.4.3 Interação com a aplicação cliente e visualização de evidências

A finalização do fluxo síncrono ocorre com o envio da resposta e das evidências associadas para a aplicação cliente LuminIA Reader. Após a inferência, o EDGAR estrutura um *payload* JSON contendo a resposta textual, a lista de componentes utilizados como evidência, seus respectivos metadados geométricos e as referências aos recortes visuais correspondentes.

Ao receber esse *payload*, o LuminIA Reader exibe a resposta no painel lateral de tutoria e utiliza os metadados espaciais para destacar, no leitor de PDF, o componente relacionado à informação apresentada. Como a interface é construída com Vue.js e PDF.js, torna-se possível controlar a página exibida, a escala de visualização e a sobreposição da camada de destaque sobre o documento. Esse mecanismo permite que o estudante acompanhe não apenas a resposta gerada, mas também a evidência documental que sustenta aquela informação.

Para esclarecer a dinâmica temporal e a troca de mensagens durante o fluxo síncrono, a Figura 2 apresenta o diagrama de sequência correspondente. O processo inicia-se com o envio da consulta pela aplicação cliente LuminIA Reader à arquitetura EDGAR. Em seguida, o EDGAR consulta o banco vetorial Qdrant para recuperar os componentes mais relevantes e seus metadados associados. Após receber essas evidências, a arquitetura estrutura o contexto e o encaminha ao modelo gerador Qwen2.5-7B. A resposta produzida retorna ao EDGAR, que consolida o *payload* final com a resposta textual, os metadados geométricos e as referências visuais necessárias para a visualização na aplicação cliente.

Figura 2 – Diagrama de sequência do fluxo síncrono de recuperação e geração da arquitetura.



Fonte: Elaborado pelo autor.

4.5 Plano de avaliação experimental

O plano de avaliação experimental do presente trabalho foi definido com o objetivo de mensurar a viabilidade técnica da arquitetura EDGAR em tarefas de consulta a materiais didáticos multimodais em PDF. O estudo buscará observar se a organização desses materiais em componentes de granularidade fina, associada à extração textual, à descrição visual, à indexação vetorial e à recuperação de metadados geométricos, contribui para a obtenção de respostas mais aderentes às evidências recuperadas.

A análise será conduzida em quatro dimensões complementares: infraestrutura de execução, composição do conjunto de teste, comparação com configurações alternativas de recuperação e aplicação de métricas de desempenho e qualidade semântica. Dessa forma, o protocolo experimental não se limita a avaliar a resposta final gerada pelo modelo de linguagem, mas também considera a eficiência do processamento, a precisão na recuperação das evidências e a rastreabilidade dos componentes utilizados na resposta.

4.5.1 Ambiente de execução e infraestrutura computacional

Para viabilizar a execução dos testes sob restrições locais de hardware, os módulos computacionais da arquitetura EDGAR serão executados em uma infraestrutura remota provisionada em ambiente de computação em nuvem. Essa infraestrutura será configurada em sistema Linux, preferencialmente com suporte a contêineres Docker, de modo a concentrar remotamente as etapas de maior custo computacional, como a execução dos modelos de linguagem, a geração de descrições visuais e a indexação dos componentes documentais.

No arranjo experimental deste trabalho, a aplicação cliente LuminIA Reader será utilizada como meio de interação com a arquitetura, permitindo o envio de documentos, a submissão de perguntas e a visualização das respostas e evidências retornadas. Essa aplicação poderá ser executada em ambiente de desenvolvimento convencional, enquanto a arquitetura concentrará as etapas de processamento documental, recuperação vetorial, engenharia de contexto e inferência. Dessa forma, preserva-se a separação entre a camada de interação com o usuário e os módulos especializados da proposta.

Durante os experimentos, serão monitorados aspectos como tempo de processamento no fluxo assíncrono, latência no fluxo síncrono, consumo de memória e taxa de geração de tokens do modelo gerador. Como a arquitetura utiliza modelos compactos da classe 7B–8B, a execução poderá empregar técnicas de otimização ou quantização, quando necessário, a fim de adequar o consumo computacional às limitações da infraestrutura disponível.

4.5.2 Conjunto de documentos e perguntas de avaliação

O conjunto de documentos de avaliação será composto por materiais didáticos reais e heterogêneos em formato PDF, com foco em disciplinas das áreas de ciências exatas e tecnológicas. Serão priorizados documentos que apresentem estrutura visual complexa, incluindo capítulos de livros, apostilas, anotações manuscritas e apresentações de slides convertidas para PDF. A seleção buscará contemplar materiais com tabelas, gráficos, diagramas, fórmulas, figuras, caixas explicativas e relações espaciais relevantes entre texto e imagem.

A partir desses documentos, será elaborado um conjunto de perguntas em linguagem natural com o objetivo de simular dúvidas comuns de estudantes durante a leitura do material. Cada pergunta será previamente associada a uma ou mais evidências esperadas no documento, registrando informações como página, tipo de componente, trecho textual de referência, descrição visual esperada e, quando aplicável, coordenadas aproximadas do elemento correspondente.

Esse mapeamento prévio permitirá avaliar não apenas se a resposta final é semanticamente adequada, mas também se o EDGAR recupera os componentes corretos entre os primeiros resultados da busca. Dessa forma, o conjunto de perguntas funcionará como base de referência para a avaliação da precisão de recuperação, da fidelidade das respostas e da capacidade do sistema em preservar a rastreabilidade entre pergunta, evidência e documento original.

4.5.3 Configurações comparativas de avaliação

Para verificar o impacto da granularidade fina proposta pela arquitetura, a avaliação será conduzida a partir de configurações comparativas. O objetivo é contrastar a arquitetura proposta com abordagens mais simples de recuperação documental, permitindo observar em que medida a segmentação por componentes, a descrição visual e a associação de metadados geométricos contribuem para a qualidade da recuperação e da geração.

A Tabela 3 apresenta as configurações previstas para comparação experimental.

Tabela 3 – Configurações comparativas previstas para a avaliação experimental.

Configuração	Descrição	Objetivo da comparação
RAG textual tradicional	Extração textual do PDF seguida de segmentação em blocos de tamanho fixo.	Verificar o desempenho de uma abordagem baseada apenas em texto linearizado.
RAG por página	Indexação e recuperação considerando páginas inteiras como unidades de contexto.	Avaliar o impacto do uso de contextos mais amplos e potencialmente mais ruidosos.
EDGAR sem descrição visual	Recuperação por componentes com texto extraído, metadados e recortes visuais, mas sem descrição visual automática.	Isolar o impacto da etapa de descrição visual sobre a recuperação e a geração.
EDGAR completo	Recuperação por componentes com texto extraído, descrição visual, recorte visual e metadados geométricos.	Avaliar a arquitetura proposta em sua configuração completa de granularidade fina.

Fonte: Elaborado pelo autor.

As configurações comparativas serão avaliadas sobre o mesmo conjunto de documentos e perguntas, de modo a permitir uma análise consistente entre os diferentes métodos. A configuração completa do EDGAR será tratada como proposta principal, enquanto as demais funcionarão como linhas de base ou variações controladas da própria arquitetura, permitindo examinar o impacto de cada decisão arquitetural sobre o desempenho do sistema.

4.5.4 Métricas e protocolo de avaliação

A avaliação será organizada em três dimensões principais: desempenho computacional, qualidade da recuperação e qualidade da resposta gerada. A dimensão de desempenho computacional será mensurada por meio de métricas temporais, incluindo o tempo total do fluxo

assíncrono de ingestão e indexação, o tempo de descrição visual dos componentes, o tempo de recuperação vetorial e a latência de ponta a ponta (L_{p2p}) no fluxo síncrono. A latência de ponta a ponta será calculada desde o envio da pergunta pelo LuminIA Reader até o recebimento do *payload* final contendo resposta, evidências e metadados.

A qualidade da recuperação será avaliada a partir da correspondência entre os componentes recuperados pelo sistema e as evidências esperadas previamente mapeadas no conjunto de perguntas. Para isso, serão consideradas métricas como Precisão de Recuperação (*Context Precision*), Recall@k e posição do primeiro componente correto no ranqueamento. Essas métricas permitirão verificar se o EDGAR consegue priorizar os blocos mais relevantes entre os primeiros resultados retornados pelo banco vetorial.

A qualidade da resposta gerada será analisada por métricas associadas a sistemas de Geração Aumentada por Recuperação, como Fidelidade Contextual (*Faithfulness*) e Relevância da Resposta (*Answer Relevance*). A Fidelidade Contextual avaliará se a resposta produzida pelo modelo gerador está sustentada pelas evidências recuperadas, enquanto a Relevância da Resposta verificará se a saída atende adequadamente à dúvida formulada pelo estudante. Sempre que necessário, a avaliação automatizada poderá ser complementada por inspeção manual, especialmente em casos que envolvam interpretação de evidências visuais ou ambiguidade na resposta.

A Tabela 4 sintetiza os principais componentes avaliados, suas especificações e as métricas associadas ao protocolo experimental.

Tabela 4 – Matriz de componentes e métricas previstas para a avaliação experimental.

Dimensão avaliada	Componente / aspecto	Métrica ou critério de avaliação
Infraestrutura	Servidor em nuvem com Docker e GPU	Uso de memória, compatibilidade de execução e estabilidade do ambiente.
Fluxo assíncrono	Ingestão, análise de layout, OCR e descrição visual	Tempo de processamento por documento e por página.
Descrição visual	Qwen2.5-VL-7B-Instruct	Tempo de geração das descrições e utilidade semântica para recuperação.
Recuperação vetorial	BGE-M3 e Qdrant	<i>Context Precision</i> , Recall@k e posição do primeiro componente correto.
Geração da resposta	Qwen2.5-7B-Instruct	<i>Faithfulness</i> , <i>Answer Relevance</i> , taxa de geração de tokens e aderência às evidências.
Fluxo síncrono	Consulta cliente-servidor	Latência de ponta a ponta (L_{p2p}), tempo de recuperação e tempo de inferência.
Rastreabilidade	Metadados geométricos e recortes visuais	Percentual de respostas com evidência visual destacável no LuminIA Reader.

Fonte: Elaborado pelo autor.

4.6 Cronograma

Nesta seção, é apresentado o cronograma de atividades planejadas para a continuidade do projeto. O planejamento contempla as etapas já realizadas no âmbito do TCC I, como a definição do tema, a revisão bibliográfica, a especificação arquitetural e a prototipagem inicial da interface, bem como as atividades previstas para a implementação, integração e avaliação experimental da arquitetura proposta.

Tabela 5 – Cronograma de atividades do projeto.

Atividades	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Definição do tema e delimitação do problema	X									
Revisão bibliográfica e trabalhos relacionados	X	X	X	X						
Especificação arquitetural do EDGAR		X	X	X						
Definição dos componentes tecnológicos e do plano de avaliação			X	X						
Prototipagem inicial da interface LuminIA Reader				X	X					
Escrita e revisão do TCC I		X	X	X	X					
Defesa do TCC I					X					
Configuração do ambiente de execução e repositórios						X				
Desenvolvimento do fluxo assíncrono de ingestão e indexação						X	X			
Desenvolvimento do fluxo síncrono de recuperação e geração							X	X		
Construção do conjunto de documentos e perguntas de avaliação							X	X		
Integração entre EDGAR e LuminIA Reader								X	X	
Implementação das configurações comparativas								X	X	
Execução da avaliação experimental									X	
Análise dos resultados e ajustes finais									X	X
Escrita e revisão do TCC II								X	X	X
Defesa do TCC II										X

Fonte: Elaborado pelo autor.

5 RESULTADOS PRELIMINARES

5.1 Resultados preliminares da arquitetura EDGAR

Nesta etapa do trabalho, os resultados preliminares concentram-se na especificação arquitetural do EDGAR e na definição dos artefatos necessários para sua implementação e avaliação experimental. Como a proposta ainda se encontra em fase de concepção e planejamento metodológico, os resultados apresentados referem-se principalmente à organização dos fluxos, à delimitação dos módulos computacionais e à estrutura esperada para os dados intermediários produzidos pela arquitetura.

Entre os principais resultados preliminares da arquitetura EDGAR, destacam-se:

- **Segmentação e análise de layout de documentos:** definição do uso de modelos de Análise de Layout de Documentos (DLA) para identificação de regiões estruturais em páginas PDF, como blocos de texto, tabelas, figuras, fórmulas e elementos gráficos. Essa etapa deverá produzir *bounding boxes* associadas a classes e índices de confiança, permitindo o isolamento dos componentes documentais em granularidade fina.
- **Estruturação de metadados documentais:** definição do formato dos metadados associados aos componentes extraídos, incluindo identificador do documento, número da página, classe do elemento, coordenadas geométricas, texto extraído, descrição visual e referência ao recorte correspondente. Essa estrutura servirá como base para a indexação vetorial, a recuperação de evidências e a posterior visualização dos componentes na aplicação cliente.

5.2 Protótipo da aplicação cliente LuminIA Reader

Como artefato de apoio à demonstração e validação prática da arquitetura EDGAR, foi prevista a utilização do LuminIA Reader como aplicação cliente. No escopo deste trabalho, o protótipo não constitui o foco principal da pesquisa, mas permite representar a forma como o estudante poderá interagir com a arquitetura, submetendo documentos, enviando perguntas e visualizando as respostas acompanhadas das evidências recuperadas.

Entre os resultados preliminares relacionados à aplicação cliente, destacam-se:

- **Ambiente de leitura e consulta:** definição de uma interface web composta por um leitor de PDF e um painel lateral de tutoria, no qual o estudante poderá submeter perguntas sobre o material didático e visualizar as respostas retornadas pelo EDGAR.

- **Visualização de evidências no documento:** definição do mecanismo de destaque visual dos componentes recuperados, utilizando os metadados geométricos retornados pela arquitetura EDGAR para indicar, no próprio PDF, a região documental associada à resposta gerada.

6 CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho apresentou a concepção da arquitetura EDGAR, uma proposta de Geração Aumentada por Recuperação Multimodal voltada à consulta de materiais didáticos em PDF. A proposta parte da necessidade de tornar mais confiável a interação entre estudantes e sistemas baseados em modelos de linguagem, especialmente em documentos compostos por texto, tabelas, gráficos, diagramas, fórmulas e outros elementos visuais relevantes para a compreensão do conteúdo.

Ao longo do estudo, foram consolidados os fundamentos teóricos relacionados a modelos de linguagem, alucinações semânticas, RAG, MRAG e análise de layout de documentos. Com base nessa fundamentação, o EDGAR foi estruturado em fluxos assíncrono e síncrono, separando o processamento prévio do documento das etapas executadas no momento da consulta. Essa organização busca permitir a construção de unidades de informação em granularidade fina, associando texto extraído, descrições visuais, recortes de componentes e metadados geométricos para apoiar respostas mais rastreáveis e aderentes ao material consultado.

Como trabalhos futuros, pretende-se implementar os fluxos de ingestão, indexação, recuperação e geração, integrar a arquitetura EDGAR à aplicação LuminIA Reader e executar o plano de avaliação experimental proposto. Essa avaliação deverá considerar aspectos de desempenho, qualidade da recuperação, fidelidade das respostas e rastreabilidade das evidências, permitindo verificar a viabilidade técnica da arquitetura em cenários controlados de consulta a materiais didáticos multimodais.

REFERÊNCIAS

- ALANSARI, A.; LUQMAN, H. Large language models hallucination: A comprehensive survey. **Computer Science Review**, Elsevier, v. 61, p. 100970, 2026.
- FAYSSE, M.; SIBILLE, H.; WU, T.; OMRANI, B.; VIAUD, G.; HUDELLOT, C.; COLOMBO, P. Colpali: Efficient document retrieval with vision language models. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2025. v. 2025, p. 61424–61449.
- GAO, Y.; XIONG, Y.; GAO, X.; JIA, K.; PAN, J.; BI, Y.; DAI, Y.; SUN, J.; WANG, H.; WANG, H. *et al.* Retrieval-augmented generation for large language models: A survey. **arXiv preprint arXiv:2312.10997**, v. 2, n. 1, p. 32, 2023.
- HOLMES, W.; MIAO, F. *et al.* **Guidance for generative AI in education and research**. [S.l.]: Unesco Publishing, 2023.
- HUANG, Y.; LV, T.; CUI, L.; LU, Y.; WEI, F. Layoutlmv3: Pre-training for document ai with unified text and image masking. In: **Proceedings of the 30th ACM international conference on multimedia**. [S.l.: s.n.], 2022. p. 4083–4091.
- JI, Z.; LEE, N.; FRIESKE, R.; YU, T.; SU, D.; XU, Y.; ISHII, E.; BANG, Y. J.; MADOTTO, A.; FUNG, P. Survey of hallucination in natural language generation. **ACM Computing Surveys**, Association for Computing Machinery (ACM), v. 55, n. 12, p. 1–38, mar. 2023. ISSN 1557-7341. Disponível em: <<http://dx.doi.org/10.1145/3571730>>.
- JURAFSKY, D.; MARTIN, J. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition**. [S.l.: s.n.], 2008. v. 2.
- KASNECI, E.; SESSLER, K.; KÜCHEMANN, S.; BANNERT, M.; DEMENTIEVA, D.; FISCHER, F.; GASSER, U.; GROH, G.; GÜNNEMANN, S.; HÜLLERMEIER, E. *et al.* Chatgpt for good? on opportunities and challenges of large language models for education. **Learning and individual differences**, Elsevier, v. 103, p. 102274, 2023.
- LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KÜTTLER, H.; LEWIS, M.; YIH, W.-t.; ROCKTÄSCHEL, T.; RIEDEL, S.; KIELA, D. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: LAROCHELLE, H.; RANZATO, M.; HADSELL, R.; BALCAN, M.; LIN, H. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2020. v. 33, p. 9459–9474. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>.
- LIU, K.; CHEN, Z.; LI, M.; TANG, J.; YANG, D.; ZHANG, L. Resolving evidence sparsity: Agentic context engineering for long-document understanding. **arXiv preprint arXiv:2511.22850**, 2025.
- LIU, N. F.; LIN, K.; HEWITT, J.; PARANJAPE, A.; BEVILACQUA, M.; PETRONI, F.; LIANG, P. Lost in the middle: How language models use long contexts. **Transactions of the association for computational linguistics**, v. 12, p. 157–173, 2024.
- MEI, L.; MO, S.; YANG, Z.; CHEN, C. A survey of multimodal retrieval-augmented generation. **arXiv preprint arXiv:2504.08748**, 2025.

- RASCHKA, S. **Build a large language model (from scratch)**. [S.l.]: Simon and Schuster, 2024.
- TUNSTALL, L.; WERRA, L. von; WOLF, T. **Natural Language Processing with Transformers: Building Language Applications with Hugging Face**. O'Reilly Media, 2022. ISBN 9781098103248. Disponível em: <https://books.google.de/books?id=_0uezgEACAAJ>.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. **Advances in neural information processing systems**, v. 30, 2017.
- WOLFRAM, S. **What Is ChatGPT Doing:... and Why Does It Work?** [S.l.]: Wolfram Media, 2023.
- XU, Y.; LI, M.; CUI, L.; HUANG, S.; WEI, F.; ZHOU, M. Layoutlm: Pre-training of text and layout for document image understanding. In: **Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining**. [S.l.: s.n.], 2020. p. 1192–1200.
- YIN, S.; FU, C.; ZHAO, S.; LI, K.; SUN, X.; XU, T.; CHEN, E. A survey on multimodal large language models. **National Science Review**, Oxford University Press (OUP), v. 11, n. 12, nov. 2024. ISSN 2053-714X. Disponível em: <<http://dx.doi.org/10.1093/nsr/nwae403>>.
- YUN, J.; LEE, D.; HAN, W.-S. Lilac: Late interacting in layered component graph for open-domain multimodal multihop retrieval. In: **Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing**. [S.l.: s.n.], 2025. p. 20551–20570.
- ZHAO, W.; ZHOU, K.; LI, J.; TIANYI, T.; DONG, Z.; HOU, Y.; ZHANG, B.; MIN, Y.; ZHANG, J.; LIU, P.; WANG, X.; DU, Y.; YANG, C.; CHEN, Y.; CHEN, Z.; JIANG, J.; REN, R.; LI, Y.; TANG, X.; WEN, J.-R. A survey of large language models. **Frontiers of Computer Science**, v. 20, 05 2026.
- ZHONG, X.; TANG, J.; YEPES, A. J. Publaynet: largest dataset ever for document layout analysis. In: IEEE. **2019 International conference on document analysis and recognition (ICDAR)**. [S.l.], 2019. p. 1015–1022.