



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS DE QUIXADÁ
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

FRANCISCO EDINALDO DOS SANTOS SILVA

**EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA RAG MULTIMODAL
PARA CONSULTA DE DOCUMENTOS DIDÁTICOS EM PDF**

QUIXADÁ

2026

FRANCISCO EDINALDO DOS SANTOS SILVA

EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA RAG MULTIMODAL PARA
CONSULTA DE DOCUMENTOS DIDÁTICOS EM PDF

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Campus de Quixadá da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Ciência da Computação.

Orientador: Prof. Dr. Cristiano Bacelar
de Oliveira

QUIXADÁ

2026

FRANCISCO EDINALDO DOS SANTOS SILVA

EDGAR: DESENVOLVIMENTO DE UMA ARQUITETURA RAG MULTIMODAL PARA
CONSULTA DE DOCUMENTOS DIDÁTICOS EM PDF

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Campus de Quixadá da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Ciência da Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Cristiano Bacelar de Oliveira (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, pelo apoio incondicional e motivo de orgulho, e aos meus amigos, que dividiram e facilitaram essa longa trajetória.

RESUMO

Este trabalho apresenta o projeto de desenvolvimento de uma arquitetura denominada "EDGAr", que integra um motor de Geração Aumentada por Recuperação Multimodal (MRAG) destinado a otimizar a compreensão de documentos no cenário educacional. O sistema é composto por pipelines de indexação híbrida e algoritmos de extração que realizam buscas de granularidade fina para verificar e isolar componentes textuais e visuais estruturados antes de formular respostas. O fluxo de dados entre os módulos ocorre via representações vetoriais, e as informações recuperadas alimentam a aplicação cliente "LuminIA Reader", que atua como camada de aplicação. O projeto visa prevenir a ocorrência de alucinações causadas por ruídos em documentos longos, garantindo contextos densos com baixo custo computacional. Os testes de arquitetura planejados buscam demonstrar a leveza do pipeline, validando sua funcionalidade e viabilidade para futuras implementações em um protótipo funcional. Esta arquitetura propõe-se como uma contribuição relevante para a tecnologia educacional, viabilizando interações mais precisas entre o estudante e o material didático ao mitigar o problema das alucinações semânticas.

Palavras-chave: Geração Aumentada por Recuperação; Visão Computacional; Materiais Didáticos; Granularidade Fina.

LISTA DE FIGURAS

LISTA DE TABELAS

Tabela 1 – Análise comparativa dos trabalhos relacionados e o presente trabalho.	20
--	----

LISTA DE SÍMBOLOS

A_e	Área efetiva da antena
B	Largura de faixa em que o ruído é medido em Hertz
d	Distância em metros
E	Campo elétrico
FA	Fator da antena
Gr	Ganho de recepção
h	Altura efetiva ou comprimento efetivo de uma antena
I	Corrente elétrica
k	Constante de Boltzmann's
K	Eficiência de irradiação
M	Variação do patamar de ruído em função da RBW
N	Condutor de neutro
NF	Figura de ruído
N_i	Potência do ruído na entrada
N_o	Potência do ruído na saída
P	Potência
R	Resistência
S_i	Potência do sinal na entrada
S_o	Potência do sinal na saída
t	Tempo
V	Tensão
Z_L	Impedância da antena
Z_o	Impedância de referência (50Ω)
λ	Comprimento de onda
Γ	Coefficiente de reflexão

SUMÁRIO

1	INTRODUÇÃO	10
1.1	Objetivos	12
1.1.1	<i>Objetivo Geral</i>	12
1.1.2	<i>Objetivos Específicos</i>	12
2	FUNDAMENTAÇÃO TEÓRICA	13
2.1	Grandes modelos de linguagem e alucinações no ensino	13
2.2	Geração aumentada por recuperação tradicional e suas limitações . . .	14
2.3	Geração aumentada por recuperação multimodal e modelos de visão . .	15
2.4	Segmentação de layout e processamento de documentos	16
3	TRABALHOS RELACIONADOS	18
3.1	ColPali: Efficient Document Retrieval with Vision Language Models . .	18
3.2	LILaC: Late Interacting in Layered Component Graph for Open-domain Multimodal Multihop Retrieval	18
3.3	SLEUTH: Resolving Evidence Sparsity via Agentic Context Engineering for Long-Document Understanding	19
3.4	Análise Comparativa	20
	REFERÊNCIAS	21

1 INTRODUÇÃO

O avanço acelerado da Inteligência Artificial (IA) generativa tem impulsionado transformações profundas no cenário educacional, com os grandes modelos de linguagem (LLMs) emergindo como ferramentas promissoras para mediar a relação entre o estudante e o conhecimento (Kasneci *et al.*, 2023). Aplicações baseadas nesses modelos passaram a ser exploradas em tarefas como tutoria automatizada, sumarização de materiais didáticos e resposta a perguntas sobre conteúdos acadêmicos, abrindo novas possibilidades para o aprendizado assistido por IA. Contudo, apesar da alta capacidade de articulação textual, esses modelos apresentam uma limitação estrutural crítica para o ambiente educacional: a alucinação semântica. Esse fenômeno é caracterizado pela geração de respostas que, embora gramaticalmente fluidas, são factualmente incorretas ou completamente desconectadas das fontes de dados consultadas, o que compromete diretamente a confiabilidade da informação entregue ao estudante (Raschka, 2024).

Para mitigar essa vulnerabilidade e ancorar as respostas em fontes de dados verificáveis, Lewis *et al.* (2020) introduziram a arquitetura de *Retrieval-Augmented Generation* (RAG). Essa abordagem atua como um intermediário que extrai blocos de informação de uma base de conhecimento externa e os injeta no contexto do modelo antes da geração da resposta, garantindo a proveniência dos dados e reduzindo a ocorrência de alucinações. No contexto educacional, essa arquitetura representa um avanço relevante, pois possibilita que sistemas de IA respondam com base no conteúdo real dos materiais didáticos fornecidos pelo próprio estudante ou pela instituição.

Entretanto, o RAG tradicional foi concebido para operar sobre repositórios textuais lineares, o que representa uma limitação significativa diante da natureza dos documentos acadêmicos reais. Conforme apontado por Gao *et al.* (2023), mecanismos de recuperação baseados puramente em texto são insuficientes para lidar com documentos cuja transmissão de conhecimento depende de layouts complexos, tabelas, infográficos e diagramas visuais, elementos amplamente presentes em livros didáticos, artigos científicos e materiais de estudo. Nesse contexto, a evolução para arquiteturas de *Multimodal Retrieval-Augmented Generation* (MRAG) impõe-se como caminho natural, uma vez que a compreensão integral de um documento educacional exige que o motor de busca seja capaz de interpretar simultaneamente as dimensões textuais e visuais que estruturam a informação.

Apesar dos avanços que a transição para MRAG representa, as soluções presentes na literatura ainda divergem entre eficiência computacional e precisão granular, não atendendo

plenamente às exigências do domínio educacional. Abordagens baseadas puramente em Visão Computacional, como a arquitetura ColPali, proposta por Faysse *et al.* (2025), introduziram a recuperação direta de imagens de páginas inteiras utilizando mecanismos de “*interação tardia*”. Apesar de serem mais rápidas por eliminarem processos custosos de reconhecimento óptico de caracteres (*Optical Character Recognition* – OCR), essas arquiteturas operam em uma granularidade fixa de página, o que frequentemente insere ruído visual irrelevante no contexto do modelo e dilui a precisão em consultas específicas.

Para contornar esse excesso de ruído e mitigar alucinações, frameworks recentes como o SLEUTH (Liu *et al.*, 2025), empregam múltiplos agentes de IA colaborativos para refinar a busca em documentos longos. Paralelamente, sistemas como o LILaC (Yun *et al.*, 2025) fragmentam o documento em grafos de componentes em camadas para interligar explicitamente parágrafos, tabelas e imagens, alcançando alta precisão em raciocínios que exigem cruzar informações de múltiplas páginas. Contudo, tanto a orquestração de múltiplos agentes quanto a construção de grafos complexos combinada com a decomposição de consultas via LLMs impõem uma elevada carga computacional e aumentam a latência do sistema.

Além disso, o foco primário dessas tecnologias tem sido o domínio aberto, científico ou administrativo, negligenciando a estrutura pedagógica única, expressa na relação direta entre teoria, exercícios e diagramas explicativos, intrínseca aos materiais didáticos.

O presente trabalho, nomeado como EDGAR, propõe a criação de uma arquitetura de Geração Aumentada por Recuperação Multimodal (MRAG) concebida e otimizada especificamente para o cenário educacional. O sistema tem como objetivo indexar e recuperar, com alta precisão e leveza computacional, tanto o conteúdo textual quanto a estrutura visual, englobando tabelas, gráficos e diagramas, de documentos didáticos complexos. Em vez de depender de uma rede custosa de múltiplos agentes ou da modelagem de grafos genéricos de domínio aberto, a solução introduz um método de indexação projetado para compreender a hierarquia semântica do material de estudo. Ao isolar e recuperar o recorte visual exato associado ao seu contexto textual correspondente, a arquitetura visa entregar um bloco de informação denso e livre de ruídos para o modelo gerador.

Dessa maneira, este projeto apresenta contribuições relevantes para a garantia da segurança, veracidade e confiabilidade da informação no processo de ensino-aprendizagem mediado por IA, visto que a ocorrência de alucinações compromete diretamente o propósito educacional da tecnologia. Para isso, a relevância do trabalho fundamenta-se na preservação

do elo pedagógico entre elementos textuais e visuais de forma alinhada à estrutura original do conteúdo. A arquitetura também viabiliza sua aplicação prática em plataformas educacionais que frequentemente operam com restrições de infraestrutura. Como resultado, a abordagem atua na mitigação proativa de falhas por meio da curadoria estrutural do contexto, reduzindo ruídos visuais e textuais antes mesmo da fase de geração da resposta pelo modelo de linguagem.

Esse parágrafo aqui ainda precisa ser feito pq não sei como fazer ainda, pois não cheguei lá que é a metodologia

1.1 Objetivos

1.1.1 Objetivo Geral

Desenvolver uma arquitetura de Geração Aumentada por Recuperação Multimodal (MRAG) capaz de realizar consultas precisas a materiais de estudo em PDF, integrando segmentação de layout e extração de elementos visuais estruturantes para mitigar proativamente alucinações semânticas no domínio educacional.

1.1.2 Objetivos Específicos

- Projetar os pipelines de processamento e indexação multimodal para isolar elementos visuais, como tabelas, gráficos e diagramas, vinculando-os de forma granular à hierarquia do contexto textual correspondente;
- Desenvolver algoritmos de refinamento contextual para isolar os fragmentos estritamente relevantes e eliminar ruídos visuais do material didático antes da fase de geração da resposta;
- Validar a eficiência e a precisão da arquitetura por meio de testes experimentais, utilizando métricas automatizadas e cenários baseados em materiais didáticos reais para avaliar o equilíbrio entre a acurácia de recuperação e a latência computacional do sistema.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos estruturais e o panorama tecnológico que sustentam o desenvolvimento deste estudo. Inicialmente, são abordados os grandes modelos de linguagem (LLMs) e o impacto das alucinações semânticas no contexto educacional na Seção 2.1. Em seguida, a Seção 2.2 detalha o funcionamento da arquitetura RAG tradicional e suas limitações diante de documentos com layouts complexos. A evolução para o paradigma multi-modal (MRAG) e a aplicação de modelos de visão computacional a documentos são discutidas na Seção 2.3. Por fim, a Seção 2.4 analisa as técnicas de segmentação de layout e extração de componentes digitais, estabelecendo os critérios utilizados no processamento de arquivos PDF.

2.1 Grandes modelos de linguagem e alucinações no ensino

A tentativa de fazer com que os computadores compreendam, interpretem e gerem a linguagem humana de forma natural é um dos desafios mais antigos e centrais da Ciência da Computação, concentrado na área de processamento de linguagem natural (PLN). Nos últimos anos, esse campo passou por uma transformação profunda com o surgimento dos LLMs. Essas ferramentas são, essencialmente, redes neurais artificiais de grande escala projetadas para simular a comunicação humana, constituindo a base tecnológica dos sistemas conversacionais e geradores de texto modernos. Esse salto de desempenho foi viabilizado pela criação da arquitetura *Transformer* (Vaswani *et al.*, 2017), que inovou ao basear-se inteiramente no mecanismo de autoatenção (*self-attention*). Essa abordagem revolucionou a área ao dispensar a leitura sequencial de uma palavra por vez, permitindo que o sistema analise todas as palavras de um texto simultaneamente. Dessa forma, a inteligência artificial consegue mapear o contexto global e entender como termos diferentes se relacionam ao longo de um documento, algo essencial para o processamento de grandes volumes de dados.

Por trás da aparente inteligência dessas ferramentas, o funcionamento básico de um LLM opera por meio de cálculo probabilístico. Diante de uma pergunta ou comando, o modelo utiliza essa rede de autoatenção não para realizar uma consulta a uma base de dados estática de verdades absolutas, mas para analisar todo o histórico do texto digitado e prever, palavra por palavra, qual é o próximo termo estatisticamente mais adequado para continuar aquela sequência (Tunstall *et al.*, 2022). Como esse processo foca em padrões numéricos e na semelhança entre as palavras, o sistema prioriza a construção de uma resposta que pareça natural e coerente para

quem lê, mesmo que não haja nenhum mecanismo nativo no modelo que verifique se aquela informação condiz com a realidade (Wolfram, 2023).

Essa natureza puramente estatística dá origem a uma limitação estrutural crítica chamada de alucinação semântica, que ocorre quando a inteligência artificial gera respostas textualmente impecáveis, mas que carregam dados falsos ou completamente inventados. Na literatura técnica, essas falhas são divididas em duas categorias: alucinações intrínsecas, quando o modelo contradiz ou ignora as informações que o próprio usuário forneceu no comando; e alucinações extrínsecas, quando o sistema introduz fatos, nomes ou regras que não existem em lugar nenhum das fontes consultadas (Ji *et al.*, 2023). Esse fenômeno acontece devido a inconsistências e vieses presentes nos dados usados para treinar a IA, além do próprio comportamento padrão do algoritmo de preferir “*completar a frase*” de forma estética a admitir que não sabe a resposta (Alansari e Luqman, 2026).

No ambiente de ensino, essa vulnerabilidade técnica ganha contornos pedagógicos graves. Ao utilizar um LLM como tutor individualizado ou assistente de estudos, estabelece-se uma relação de confiança entre o estudante e a ferramenta (Kasneci *et al.*, 2023). No entanto, como o aluno está justamente no momento de adquirir e consolidar o conhecimento, ele frequentemente não possui o repertório necessário para desconfiar do sistema. O maior perigo reside nas alucinações sutis: respostas escritas com extrema eloquência e autoridade, mas que trazem erros conceituais velados. Esse tipo de falha induz o estudante ao erro de forma silenciosa, consolidando equívocos teóricos e comprometendo a segurança do processo de aprendizado (Holmes *et al.*, 2023).

2.2 Geração aumentada por recuperação tradicional e suas limitações

Como forma de mitigar as alucinações semânticas e estender a base de conhecimento dos LLMs sem a necessidade de novos treinamentos custosos, a comunidade de inteligência artificial desenvolveu o conceito de Geração Aumentada por Recuperação (RAG) (Lewis *et al.*, 2020). Em sua abordagem tradicional, também conhecida como RAG linear ou baseada puramente em texto, o funcionamento do sistema baseia-se em acoplar um motor de busca a um modelo gerador. O processo começa com a preparação dos documentos de suporte, em que arquivos de texto longo são segmentados em blocos menores de tamanho fixo, técnica denominada *chunking*. Em seguida, esses blocos textuais são convertidos em vetores numéricos de alta dimensão, os *embeddings*, que capturam o significado semântico das palavras e são

armazenados em um banco de dados vetorial especializado (Gao *et al.*, 2023).

A dinâmica de consulta desse ecossistema ocorre em tempo de execução a partir da interação do usuário. Quando um estudante submete uma pergunta à plataforma, essa requisição passa pelo mesmo modelo de conversão para gerar um vetor de busca. O sistema realiza, então, uma busca vetorial no banco de dados por meio de cálculos de proximidade espacial, como a similaridade de cosseno, localizando os blocos de texto que possuem o contexto mais alinhado à dúvida enviada (Tunstall *et al.*, 2022). Esses fragmentos de texto recuperados são injetados diretamente no prompt de entrada do LLM, servindo como uma base de conhecimento contextual estendida. Com esse embasamento factual fixado em seu contexto de entrada, o modelo gerador deixa de depender exclusivamente de sua memória probabilística interna para construir a resposta final, reduzindo drasticamente as chances de inventar informações (Lewis *et al.*, 2020).

Apesar do sucesso dessa abordagem para textos corridos e lineares, o RAG tradicional enfrenta severas limitações estruturais quando aplicado a documentos de layout complexo, como livros didáticos e materiais de estudo em formato PDF. O primeiro grande gargalo reside na perda total de elementos não textuais: tabelas, gráficos, infográficos e diagramas explicativos são completamente ignorados pelos extratores de texto padrão, deixando o LLM sem acesso a dados visuais fundamentais para o aprendizado (Faysse *et al.*, 2025). Além disso, a quebra cega do documento em blocos de tamanho fixo corrompe a ordem lógica da informação. Em materiais educacionais, é comum que a explicação teórica esteja disposta ao lado de uma imagem ou distribuída em caixas de destaque; contudo, a leitura linear do RAG ignora essa hierarquia visual e mistura fragmentos desconexos, gerando ruído e comprometendo a qualidade do contexto que subsidia o modelo de linguagem (Gao *et al.*, 2023).

2.3 Geração aumentada por recuperação multimodal e modelos de visão

Para superar as barreiras do RAG tradicional na interpretação de layouts complexos, a área de inteligência artificial evoluiu em direção à Geração Aumentada por Recuperação Multimodal (MRAG) (Mei *et al.*, 2025). A principal evolução desse paradigma está na capacidade de alinhar diferentes modalidades de dados, como texto e imagem, dentro de um mesmo espaço vetorial matemático. Sob essa nova ótica, o sistema deixa de fragmentar o documento em linhas de texto isoladas e passa a tratar o material didático a partir de representações visuais unificadas. Isso significa que o modelo consegue correlacionar semanticamente uma dúvida textual submetida por um estudante à imagem correspondente de um gráfico ou tabela que

responda àquela questão, conferindo aos elementos visuais o mesmo peso e relevância dos blocos de texto (Mei *et al.*, 2025).

Essa abordagem foi viabilizada pelo surgimento dos modelos de linguagem e visão (*Vision-Language Models* – VLMs), componentes capazes de processar diretamente as capturas de tela das páginas dos documentos sem a necessidade de intermediários como softwares de processamento OCR. Um marco importante nessa evolução foi a introdução da arquitetura *ColPali*, que utiliza o conceito de *Late Interaction* (interação tardia) para realizar a busca de documentos de forma eficiente (Faysse *et al.*, 2025). Em vez de compactar uma página inteira em um único vetor, o sistema gera múltiplos *embeddings* para cada região da imagem, permitindo que o mecanismo de busca analise os detalhes visuais e textuais simultaneamente em nível granular. Esse processo garante que tabelas complexas, fórmulas matemáticas e infográficos sejam indexados com alta fidelidade semântica, aproximando a busca computacional da forma como um ser humano examina um documento visualmente (Faysse *et al.*, 2025).

Apesar do avanço no mapeamento visual de documentos, as implementações atuais de MRAG introduziram um novo desafio técnico associado ao ruído contextual. Como sistemas baseados no *ColPali* costumam recuperar e enviar a captura da página inteira como contexto para o LLM gerar a resposta, o modelo gerador acaba sobrecarregado com informações irrelevantes contidas na mesma folha, tais como cabeçalhos, rodapés, números de página e parágrafos de assuntos adjacentes (Faysse *et al.*, 2025). Esse excesso de dados visuais desnecessários satura a janela de contexto da inteligência artificial e dispersa a atenção do mecanismo gerador, reabrindo margem para a ocorrência de alucinações semânticas. Torna-se imperativo, portanto, o desenvolvimento de estratégias de engenharia voltadas ao isolamento granular dos componentes visuais relevantes, limpando o contexto antes da fase de geração (Faysse *et al.*, 2025).

2.4 Segmentação de layout e processamento de documentos

Para solucionar o problema do ruído contextual gerado pela captura de páginas inteiras, a engenharia de software e a visão computacional aplicam as técnicas de análise de layout de documentos (*Document Layout Analysis* – DLA) (Zhong *et al.*, 2019). Essa subárea estuda metodologias para fazer com que os algoritmos compreendam a estrutura geométrica e a organização lógica de um arquivo digital. Em vez de tratar o documento PDF como uma sequência linear de caracteres ou como uma imagem única e indivisível, os modelos de DLA escaneiam a página para identificar e delimitar os componentes estruturais por meio de caixas

envolventes, conhecidas como *bounding boxes*. Esse mapeamento automático permite determinar as coordenadas bidimensionais exatas (X, Y) de cada bloco de informação, segmentando o arquivo em entidades lógicas independentes (Zhong *et al.*, 2019).

O avanço na precisão dessa segmentação foi impulsionado pelo surgimento de modelos de aprendizado profundo híbridos, com destaque para a família *LayoutLM* (Xu *et al.*, 2020). Diferente das abordagens passadas que analisavam apenas o texto ou apenas a imagem de forma isolada, essa arquitetura provou matematicamente a necessidade de processar o conteúdo textual alinhado à sua respectiva posição espacial na página. Modelos mais recentes, como o *LayoutLMv3*, consolidaram esse avanço ao unificar o aprendizado multimodal através de objetivos de pré-treinamento que consideram texto, imagem e a geometria do layout simultaneamente (Huang *et al.*, 2022). Essa tecnologia confere aos sistemas a capacidade de classificar com alta precisão a natureza de cada bloco detectado, separando com clareza elementos de descarte, como cabeçalhos e rodapés, de componentes de alto valor pedagógico, como tabelas, gráficos e caixas de texto explicativas (Huang *et al.*, 2022).

Uma vez identificadas e classificadas as coordenadas estruturais do documento, torna-se possível aplicar uma engenharia de processamento focada na filtragem granular dos dados. A partir da localização exata do elemento relevante determinada pelos modelos de DLA, o sistema consegue executar uma operação de recorte digital, o *cropping*, isolando apenas o bloco de interesse e eliminando os ruídos visuais ao redor (Zhong *et al.*, 2019). Esse processo de refino e curadoria de layout garante que apenas o conteúdo estritamente necessário e livre de distrações textuais seja encapsulado e enviado para alimentar a janela de contexto do modelo gerador final. Desse modo, a integração entre a busca visual avançada e os algoritmos de segmentação estrutural estabelece o alicerce técnico ideal para blindar o ecossistema contra alucinações conceituais no cenário educativo.

3 TRABALHOS RELACIONADOS

Neste capítulo, são apresentados trabalhos recentes que abordam o problema da recuperação multimodal em documentos complexos, destacando os pontos de convergência com a presente proposta e as limitações que motivam o desenvolvimento do EDGAR.

3.1 ColPali: Efficient Document Retrieval with Vision Language Models

Faysse *et al.* (2025) propõem o ColPali, uma arquitetura de recuperação de documentos que substitui os tradicionais pipelines de extração de texto por um modelo de linguagem e visão (VLM) capaz de indexar páginas inteiras como representações visuais. O sistema opera por meio de um mecanismo de interação tardia (*late interaction*), que compara vetores de *patches* visuais da página com o vetor da consulta do usuário, eliminando a necessidade de OCR e reduzindo significativamente o custo de indexação. Essa abordagem demonstrou resultados competitivos em benchmarks de recuperação de documentos com layouts complexos, como tabelas e infográficos.

Em comparação, o presente trabalho compartilha com o ColPali o reconhecimento de que elementos visuais são componentes fundamentais para a compreensão de documentos complexos e que abordagens puramente textuais são insuficientes para esse domínio. Contudo, o EDGAR se diferencia ao operar em uma granularidade significativamente mais fina: enquanto o ColPali trata a página inteira como unidade de recuperação, frequentemente introduzindo ruído visual irrelevante no contexto do modelo, o presente trabalho isola componentes estruturais específicos, como parágrafos, tabelas, figuras e legendas, preservando o elo pedagógico entre eles. Além disso, o foco do ColPali recai sobre a eficiência de recuperação em domínio aberto, ao passo que o EDGAR é orientado à estrutura semântica intrínseca dos materiais didáticos, em que a relação entre teoria e elemento visual constitui uma unidade de conhecimento indivisível.

3.2 LILaC: Late Interacting in Layered Component Graph for Open-domain Multimodal Multihop Retrieval

Yun *et al.* (2025) apresentam o LILaC, um framework de recuperação multimodal que estrutura documentos como grafos de componentes em camadas, interligando explicitamente parágrafos, tabelas e imagens por meio de arestas semânticas e estruturais. Essa representação em grafo permite que o sistema realize raciocínios que exigem o cruzamento de informações

distribuídas em múltiplas páginas, alcançando alta precisão em tarefas de recuperação multimodal multi-salto (*multihop*) em domínio aberto.

O presente trabalho converge com o LILaC ao reconhecer que a relação entre os componentes de um documento, e não apenas o conteúdo isolado de cada um, é determinante para a qualidade da recuperação. Entretanto, o EDGAR se diferencia pela abordagem adotada para preservar essas relações. A construção de grafos de componentes combinada com a decomposição de consultas via LLMs impõe ao LILaC uma elevada carga computacional, tornando-o pouco viável para plataformas educacionais com recursos limitados. O presente trabalho propõe uma alternativa mais leve, baseada em pipelines de indexação híbrida que capturam a hierarquia estrutural do documento sem a sobrecarga da construção e manutenção de grafos complexos. Ademais, enquanto o LILaC foca no domínio aberto e científico, o EDGAR é especificamente orientado à estrutura pedagógica dos materiais didáticos em PDF, domínio cujas particularidades, como a relação direta entre enunciado, diagrama e exercício, não são contempladas pelo framework relacionado.

3.3 SLEUTH: Resolving Evidence Sparsity via Agentic Context Engineering for Long-Document Understanding

Liu *et al.* (2025) propõem o SLEUTH, um framework baseado em engenharia de contexto agêntica para a compreensão de documentos longos. O sistema emprega múltiplos agentes de inteligência artificial colaborativos que refinam iterativamente a busca por evidências esparsas ao longo do documento, decompondo consultas complexas em sub-tarefas e consolidando os fragmentos recuperados em um contexto coerente para o modelo gerador. Essa abordagem demonstrou resultados expressivos em tarefas de compreensão que exigem raciocínio sobre evidências distribuídas em documentos extensos.

Em comparação, o presente trabalho compartilha com o SLEUTH o objetivo de mitigar alucinações semânticas por meio de uma curadoria cuidadosa do contexto entregue ao modelo de linguagem, especialmente em documentos longos em que a dispersão da informação representa um risco para a qualidade da resposta gerada. No entanto, o EDGAR se distingue pela estratégia adotada para alcançar esse objetivo. A orquestração de múltiplos agentes impõe ao SLEUTH uma latência elevada e um custo computacional significativo, uma vez que cada consulta aciona um ciclo iterativo de decomposição e refinamento. O presente trabalho trata a curadoria do contexto como uma etapa estrutural do pipeline de indexação, e não como um

processo reativo em tempo de consulta, minimizando os ruídos antes mesmo da fase de geração da resposta e reduzindo a dependência de recursos computacionais intensivos. Essa escolha arquitetural torna o EDGAR mais adequado ao cenário educacional, em que a viabilidade de implantação em plataformas com infraestrutura limitada é um requisito prático fundamental.

3.4 Análise Comparativa

A Tabela 1 sintetiza os principais eixos de diferenciação entre os trabalhos relacionados e a arquitetura proposta neste trabalho. Os critérios de comparação foram selecionados com base nas dimensões mais relevantes para o domínio educacional: a precisão da recuperação, o custo computacional associado e a capacidade de lidar com a estrutura multimodal e pedagógica dos materiais didáticos em PDF.

Tabela 1 – Análise comparativa dos trabalhos relacionados e o presente trabalho.

Critério	ColPali	LILaC	SLEUTH	EDGAR
Granularidade de recuperação	Página inteira	Componente via grafo	Trecho por agente	Componente isolado
Custo computacional	Baixo	Alto	Alto	Baixo
Suporte a elementos visuais	Sim	Sim	Parcial	Sim
Preserva relações entre componentes	Não	Sim	Parcial	Sim
Orquestração de múltiplos agentes	Não	Não	Sim	Não
Mitigação proativa de alucinações	Não	Não	Não	Sim
Foco em domínio educacional	Não	Não	Não	Sim
Requer OCR	Não	Sim	Sim	Sim

Fonte: Elaborado pelo autor (2025).

A análise evidencia que, embora os trabalhos relacionados apresentem contribuições relevantes para a recuperação multimodal, nenhum deles concilia simultaneamente baixo custo computacional, granularidade fina de recuperação e sensibilidade à estrutura pedagógica dos documentos. O ColPali, apesar de sua eficiência, opera em granularidade de página inteira, o que frequentemente introduz ruído visual no contexto do modelo. O LILaC e o SLEUTH alcançam maior precisão, porém ao custo de uma arquitetura computacionalmente intensiva, inviável para plataformas educacionais com recursos limitados. O EDGAR propõe-se a ocupar essa lacuna, combinando recuperação em nível de componente isolado com baixo custo computacional e mitigação proativa de alucinações, características orientadas especificamente às demandas do domínio educacional.

REFERÊNCIAS

- ALANSARI, A.; LUQMAN, H. Large language models hallucination: A comprehensive survey. **Computer Science Review**, Elsevier, v. 61, p. 100970, 2026.
- FAYSSE, M.; SIBILLE, H.; WU, T.; OMRANI, B.; VIAUD, G.; HUDELOT, C.; COLOMBO, P. Colpali: Efficient document retrieval with vision language models. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2025. v. 2025, p. 61424–61449.
- GAO, Y.; XIONG, Y.; GAO, X.; JIA, K.; PAN, J.; BI, Y.; DAI, Y.; SUN, J.; WANG, H.; WANG, H. *et al.* Retrieval-augmented generation for large language models: A survey. **arXiv preprint arXiv:2312.10997**, v. 2, n. 1, p. 32, 2023.
- HOLMES, W.; MIAO, F. *et al.* **Guidance for generative AI in education and research**. [S.l.]: Unesco Publishing, 2023.
- HUANG, Y.; LV, T.; CUI, L.; LU, Y.; WEI, F. Layoutlmv3: Pre-training for document ai with unified text and image masking. In: **Proceedings of the 30th ACM international conference on multimedia**. [S.l.: s.n.], 2022. p. 4083–4091.
- JI, Z.; LEE, N.; FRIESKE, R.; YU, T.; SU, D.; XU, Y.; ISHII, E.; BANG, Y. J.; MADOTTO, A.; FUNG, P. Survey of hallucination in natural language generation. **ACM Computing Surveys**, Association for Computing Machinery (ACM), v. 55, n. 12, p. 1–38, mar. 2023. ISSN 1557-7341. Disponível em: <<http://dx.doi.org/10.1145/3571730>>.
- KASNECI, E.; SESSLER, K.; KÜCHEMANN, S.; BANNERT, M.; DEMENTIEVA, D.; FISCHER, F.; GASSER, U.; GROH, G.; GÜNNEMANN, S.; HÜLLERMEIER, E. *et al.* Chatgpt for good? on opportunities and challenges of large language models for education. **Learning and individual differences**, Elsevier, v. 103, p. 102274, 2023.
- LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KÜTTLER, H.; LEWIS, M.; YIH, W.-t.; ROCKTÄSCHEL, T.; RIEDEL, S.; KIELA, D. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: LAROCHELLE, H.; RANZATO, M.; HADSELL, R.; BALCAN, M.; LIN, H. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2020. v. 33, p. 9459–9474. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>.
- LIU, K.; CHEN, Z.; LI, M.; TANG, J.; YANG, D.; ZHANG, L. Resolving evidence sparsity: Agentic context engineering for long-document understanding. **arXiv preprint arXiv:2511.22850**, 2025.
- MEI, L.; MO, S.; YANG, Z.; CHEN, C. A survey of multimodal retrieval-augmented generation. **arXiv preprint arXiv:2504.08748**, 2025.
- RASCHKA, S. **Build a large language model (from scratch)**. [S.l.]: Simon and Schuster, 2024.
- TUNSTALL, L.; WERRA, L. von; WOLF, T. **Natural Language Processing with Transformers: Building Language Applications with Hugging Face**. O'Reilly Media, 2022. ISBN 9781098103248. Disponível em: <https://books.google.de/books?id=_0uezgEACAAJ>.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. **Advances in neural information processing systems**, v. 30, 2017.

WOLFRAM, S. **What Is ChatGPT Doing:... and Why Does It Work?** [S.l.]: Wolfram Media, 2023.

XU, Y.; LI, M.; CUI, L.; HUANG, S.; WEI, F.; ZHOU, M. Layoutlm: Pre-training of text and layout for document image understanding. In: **Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining**. [S.l.: s.n.], 2020. p. 1192–1200.

YUN, J.; LEE, D.; HAN, W.-S. Lilac: Late interacting in layered component graph for open-domain multimodal multihop retrieval. In: **Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing**. [S.l.: s.n.], 2025. p. 20551–20570.

ZHONG, X.; TANG, J.; YEPES, A. J. Publaynet: largest dataset ever for document layout analysis. In: IEEE. **2019 International conference on document analysis and recognition (ICDAR)**. [S.l.], 2019. p. 1015–1022.